INSTITUTO TECNOLÓGICO DE AERONÁUTICA

João Matheus Del Vecchio

Estimação Neural de Processos de Hawkes em Dados de Criptomoedas de Alta Frequência

Rascunho de dissertação — reprodução de LSTM e extensão com atenção

São José dos Campos

2026

Resumo

Processos de Hawkes descrevem sequências de eventos em que cada ocorrência eleva temporariamente a probabilidade de novas ocorrências; em microestrutura financeira, representam o agrupamento de alterações de preço. Este trabalho reproduz e estende a estimação amortizada, por redes neurais, dos parâmetros de um Hawkes bidimensional simétrico proposta por Lee [28], com dados de alta frequência dos futuros perpétuos BTCUSDT e ETHUSDT da Binance. Foi construída uma pipeline reproduzível que reconstrói o mid-price em grade de 100 ms (1.826.904 eventos na janela principal e 1.288.352 na de robustez), simula trajetórias por *thinning* de Ogata, estima parâmetros por máxima verossimilhança (MLE) e treina uma LSTM, como no artigo, e um encoder Transformer. No protocolo sintético congelado (75.000/10.000/15.000 trajetórias de 1.000 eventos e cinco seeds por rede), a LSTM obteve MSE macro de 0,0196 e o Transformer, 0,0237; com cinco seeds, a diferença não é significativa ($p = 0{,}19$), e o ensemble da LSTM supera o do Transformer em 70% das trajetórias. O MSE macro do MLE (0,506) é dominado por 1% das trajetórias, nas quais β é pouco identificado por causa da excitação fraca; na trajetória típica, o MLE é tão preciso quanto as redes e melhor em α_{self} e α_{cross}. No ponto fixo publicado por Lee [28], o experimento reproduz o padrão do artigo: redes com viés de encolhimento e MLE quase não viesado. Um benchmark controlado mostrou custo de cerca de 10 ms por trajetória para o MLE e de 5 a 10 ms para as redes em lote unitário; a vantagem de velocidade das redes aparece apenas na inferência em lote. Por fim, o MLE em 1.063 janelas reais de calibração indicou excitação cruzada praticamente nula e β mediano de 2,7, fora do suporte usado no treino; por isso, a adaptação empírica exige recalibrar o prior ou treinar com rótulos MLE em janelas reais. Conclui-se que a atenção não superou a LSTM nesse problema e que a principal vantagem da estimação amortizada é a robustez e o custo em lote, não a precisão por trajetória.

Palavras-chave: processos de Hawkes; alta frequência; criptomoedas; LSTM; Transformer;

estimação amortizada.

Abstract

Hawkes processes describe event sequences in which each occurrence temporarily raises the probability of further occurrences; in market microstructure they represent the clustering of price changes. This work reproduces and extends the amortized neural estimation of a symmetric bivariate Hawkes process proposed by Lee [28], using high-frequency data from Binance BTCUSDT and ETHUSDT perpetual futures. A reproducible pipeline reconstructs the mid-price on a 100 ms grid (1,826,904 events in the primary window and 1,288,352 in the robustness window), simulates paths by Ogata thinning, estimates parameters by maximum likelihood (MLE), and trains the paper's LSTM and a Transformer encoder. Under the frozen synthetic protocol (75,000/10,000/15,000 paths of 1,000 events, five seeds per network), the LSTM reached a macro MSE of 0.0196 and the Transformer 0.0237; with five seeds the difference is not significant ($p = 0.19$), and the LSTM ensemble beats the Transformer ensemble on 70% of the paths. The MLE macro MSE (0.506) is driven by 1% of the paths, in which β is weakly identified because excitation is low; on a typical path the MLE is as accurate as the networks and better for α_{self} and α_{cross}. At the fixed point published by Lee [28], the experiment reproduces the paper's pattern: shrinkage bias for the networks and a nearly unbiased MLE. A controlled benchmark measured about 10 ms per path for the MLE and 5 to 10 ms for the networks at batch size one, so the speed advantage of the networks appears only in batched inference. Finally, MLE fits on 1,063 real calibration windows show near-zero cross-excitation and a median β of 2.7, outside the training support; the empirical adaptation therefore requires a recalibrated prior or training on MLE-labelled real windows. Attention did not outperform the LSTM on this problem, and the main benefit of amortized estimation is robustness and batched cost rather than per-path accuracy.

Keywords: Hawkes processes; high frequency; cryptocurrencies; LSTM; Transformer; amortized inference.

Sumário

1 Introdução **1**

1.1 Contexto 1

1.2 Problema 1

1.3 Hipóteses 2

1.4 Objetivos 2

1.5 Contribuições 3

2 Fundamentação teórica **4**

2.1 Processos pontuais 4

2.2 Poisson como modelo nulo 4

2.3 Hawkes univariado 5

2.4 Hawkes bidimensional simétrico 5

2.5 Estabilidade 5

2.6 Marcas e preço 6

2.7 Volatilidade 6

2.8 Máxima verossimilhança 6

2.9 Identificabilidade em amostras finitas 6

2.10 Estimação amortizada como estimador de Bayes 7

2.11 LSTM 7

2.12 Atenção e Transformer 7

3 Trabalhos relacionados **9**

3.1 Processos de Hawkes em finanças 9

3.2 Estimação de processos de Hawkes 9

3.3 Inferência amortizada e baseada em simulação 10

3.4 Processos pontuais neurais . . . 10
3.5 Hawkes em criptoativos . . . 10
3.6 Posicionamento . . . 10

4 Dados **12**
4.1 Fonte e mercado . . . 12
4.2 Schema . . . 12
4.3 Amostragem . . . 12
4.4 Datasets produzidos . . . 13
4.5 Características dos eventos . . . 13

5 Metodologia **14**
5.1 Princípios . . . 14
5.2 Pipeline . . . 14
5.3 Simulação por thinning . . . 15
5.4 MLE restrito . . . 15
5.5 Protocolo neural . . . 15
5.6 Ponto fixo do artigo (E2) . . . 16
5.7 Métricas e testes . . . 16

6 Resultados **18**
6.1 Gate de dados . . . 18
6.2 Reprodução no ponto fixo . . . 18
6.3 Comparação final: LSTM, Transformer e MLE . . . 19
6.4 Análise complementar dos resultados sintéticos . . . 20
6.5 Calibração empírica e suporte do prior sintético . . . 23
6.6 Custo computacional . . . 23
6.7 Calibração empírica . . . 25

7 Discussão **26**
7.1 Avaliação das hipóteses . . . 26
7.2 Por que as redes vencem no MSE agregado . . . 26
7.3 Comparação com Lee (2023) . . . 27
7.4 Implicações para a etapa empírica . . . 27

7.5 Ameaças à validade 27

8 Trabalhos futuros **29**

9 Conclusão **30**

A Ambiguidades de Lee (2023) **31**

B Reprodução computacional **32**

C Histórico de validação da pipeline **33**

Lista de Tabelas

3.1 Posicionamento do trabalho em relação à literatura próxima. 11

4.1 Cobertura dos datasets. 13
4.2 Características dos eventos de mid-price, 15 a 22 de janeiro de 2024. 13

5.1 Configuração e custo do treinamento (cinco seeds por rede, Mac Apple Silicon com MPS). 16

6.1 Distribuição amostral no ponto fixo de Lee [28] ($\mu = 0{,}3$, $\alpha_{\text{self}} = 0{,}4$, $\alpha_{\text{cross}} = 0{,}7$, $\beta = 1{,}5$): média e desvio-padrão em 2.000 trajetórias de 1.000 eventos. As linhas de Lee usam 100.000 trajetórias de 2.000 passos. 18
6.2 Métricas agregadas no teste sintético congelado (15.000 trajetórias de 1.000 eventos). 19
6.3 MSE de teste por parâmetro (redes: média de cinco seeds). 19
6.4 MSE macro por regime da razão de ramificação g. 19
6.5 R^2 por parâmetro em relação à média a priori, erro absoluto mediano macro e MSE da razão de ramificação no teste sintético. 22
6.6 Comparação pareada por trajetória (erro quadrático padronizado médio nos quatro parâmetros). Colunas: perda mediana de A e de B, fração de trajetórias em que A erra menos e IC 95% *bootstrap* da diferença média A−B (negativo favorece A). 22
6.7 Custo por trajetória de 1.000 eventos em benchmark controlado. 24

C.1 Testes de integração anteriores ao protocolo congelado. 33

Lista de Figuras

6.1 MSE de teste por parâmetro no protocolo de 1.000 eventos. As barras de erro das redes representam um desvio-padrão entre seeds. 20
6.2 MSE macro por regime da razão de ramificação. As barras de erro das redes representam um desvio-padrão entre seeds. 21
6.3 Custo por trajetória registrado durante a execução final, em escala logarítmica. Para o MLE, tempo de parede com quatro processos que concorriam com o treino na GPU; para as redes, latência mediana em batch unitário no MPS. Um benchmark controlado posterior mediu cerca de 10 ms por trajetória para o MLE em um único núcleo e deve ser preferido a esta figura. 21
6.4 β verdadeiro versus estimado (3.000 trajetórias de teste, escala logarítmica). As redes encolhem as estimativas para o centro do prior; o MLE é não viesado na maior parte do domínio, mas produz valores extremos quando g é baixo. 23
6.5 Estimativas MLE nas janelas reais de calibração (pontos) e suporte do prior usado para gerar os dados de treino (retângulos). 24

Capítulo 1

Introdução

1.1 Contexto

Preços financeiros não mudam em intervalos regulares. Em escalas curtas, observa-se uma sequência de eventos: alteração para cima, alteração para baixo, negociação, inclusão ou remoção de ordem. A atividade alterna períodos calmos e rajadas. Essa dependência temporal é chamada de *clustering* e está ligada à volatilidade [7].

Um processo de Poisson homogêneo supõe taxa constante e incrementos independentes. Essa hipótese é útil como ponto de partida, mas incapaz de representar o fato de que uma mudança recente costuma ser seguida por mais mudanças. O processo de Hawkes [21, 22] corrige essa limitação ao tornar a intensidade dependente da própria história e tornou-se um modelo de referência em finanças de alta frequência [4, 23].

O desafio prático é estimar os parâmetros. MLE possui base estatística clara, porém exige otimização iterativa para cada nova janela. Lee [28] propõe pagar um custo de treinamento uma vez e usar uma LSTM para mapear diretamente a sequência observada nos parâmetros. Essa estratégia é *inferência amortizada*: várias inferências futuras reutilizam o conhecimento aprendido [12].

1.2 Problema

O artigo de referência utiliza ações dos Estados Unidos entre 2018 e 2019. Seus dados NBBO não foram publicados, e detalhes importantes do protocolo estão ausentes. Além disso, somente uma arquitetura recorrente compacta foi estudada. Criptoativos oferecem

um caso de teste natural: negociação contínua, 24 horas por dia, e dados públicos de melhor oferta [33]. O presente trabalho pergunta:

> Uma arquitetura com atenção consegue estimar parâmetros de um Hawkes 2D em movimentos de preço de criptomoedas com acurácia e estabilidade iguais ou superiores à LSTM de Lee, preservando inferência mais rápida que MLE?

1.3 Hipóteses

As hipóteses foram registradas antes da execução final e são mantidas como foram escritas:

H1. Dados públicos USD-M da Binance permitem construir sequências equivalentes em estrutura às entradas de Lee.

H2. A LSTM alcança erro da mesma ordem do MLE com latência substancialmente menor.

H3. A atenção melhora erro ou robustez em sequências com dependências longas.

H3 pode ser rejeitada. Um resultado negativo, se obtido sob protocolo congelado, é cientificamente informativo.

1.4 Objetivos

O objetivo geral é reproduzir e estender a estimação neural de Hawkes em cripto. Objetivos específicos:

1. construir e auditar o dataset de top-of-book;
2. implementar Hawkes 2D, simulação e MLE;
3. reproduzir a LSTM do artigo;
4. adaptar a pipeline a BTCUSDT e ETHUSDT;
5. projetar Transformer comparável;
6. avaliar acurácia, validade, custo e robustez;
7. aplicar o melhor estimador à volatilidade Hawkes.

Os objetivos 4 e 7 dependem da etapa empírica descrita no Capítulo 8.

1.5 Contribuições

A primeira contribuição é de reprodução: código aberto, registro das lacunas do artigo e reprodução quantitativa da distribuição amostral no ponto fixo publicado. A segunda é metodológica: separação explícita entre reprodução sintética, adaptação empírica e extensão, com testes estatísticos pareados e métricas robustas que mostram por que o MSE agregado favorece as redes. A terceira é arquitetural: comparação justa de LSTM e Transformer, com resultado negativo para a atenção. A quarta é empírica: caracterização dos eventos de mid-price de BTCUSDT e ETHUSDT e evidência de que seus parâmetros estimados ficam fora da região típica de ações.

Capítulo 2

Fundamentação teórica

2.1 Processos pontuais

Se $t_1 < t_2 < \cdots$ são instantes de evento, o processo de contagem é

$$N(t) = \sum_k \mathbf{1}_{\{t_k \le t\}}.$$

A intensidade condicional $\lambda(t \mid \mathcal{H}_t)$ descreve a taxa instantânea esperada dado o histórico $\mathcal{H}_t$ [13]. Informalmente,

$$\Pr[N(t + \mathrm{d}t) - N(t) = 1 \mid \mathcal{H}_t] \approx \lambda(t)\,\mathrm{d}t.$$

Não se trata de probabilidade em unidade arbitrária: intensidade possui dimensão de eventos por unidade de tempo.

2.2 Poisson como modelo nulo

No Poisson homogêneo, $\lambda(t) = \lambda_0$. Tempos entre eventos são exponenciais independentes. O modelo não produz rajadas além do acaso. Portanto, é um controle útil: se Hawkes não superar Poisson em diagnóstico, a autoexcitação não está justificada.

2.3 Hawkes univariado

Com kernel exponencial,

$$\lambda(t) = \mu + \sum_{t_k<t} \alpha e^{-\beta(t-t_k)}.$$

μ é atividade exógena; α é o salto imediato; β controla a velocidade de esquecimento. A integral do kernel é α/β, a razão de ramificação [27].

2.4 Hawkes bidimensional simétrico

Altas e baixas são processos N_1, N_2:

$$\lambda_1(t) = \mu + \sum_{t_k^1<t} \alpha_{\text{self}} e^{-\beta(t-t_k^1)} + \sum_{t_k^2<t} \alpha_{\text{cross}} e^{-\beta(t-t_k^2)}, \tag{2.1}$$

$$\lambda_2(t) = \mu + \sum_{t_k^2<t} \alpha_{\text{self}} e^{-\beta(t-t_k^2)} + \sum_{t_k^1<t} \alpha_{\text{cross}} e^{-\beta(t-t_k^1)}. \tag{2.2}$$

O modelo reduz uma matriz geral a quatro parâmetros. Essa parcimônia facilita simulação e comparação com Lee [28]. Em microestrutura, excitação cruzada dominante indica reversão (uma alta seguida de baixa), e autoexcitação dominante indica persistência de direção [3].

2.5 Estabilidade

A matriz de massa dos kernels é

$$\mathbf{G} = \frac{1}{\beta} \begin{bmatrix} \alpha_{\text{self}} & \alpha_{\text{cross}} \\ \alpha_{\text{cross}} & \alpha_{\text{self}} \end{bmatrix}.$$

Seu maior autovalor é

$$g = \frac{\alpha_{\text{self}} + \alpha_{\text{cross}}}{\beta}.$$

Exige-se $g < 1$. Perto de um, cascatas duram mais; acima de um, não há regime estacionário usual [18, 20].

2.6 Marcas e preço

Um evento tem tempo, tipo e marca. A marca é o tamanho da mudança em ticks. O artigo preserva a marca para volatilidade, mas supõe que a intensidade não depende dela. O preço filtrado pode ser escrito, em ticks, como diferença acumulada entre altas e baixas.

2.7 Volatilidade

Em um modelo mínimo, se o preço se move por um tick ϑ a uma taxa ϕ,

$$\sigma^2 \approx \phi\vartheta^2.$$

Assim, modelar intensidade é modelar atividade e, por consequência, uma componente da volatilidade. A expressão de Hawkes marcada requer momentos das marcas e parâmetros estimados [29, 30]. A realized volatility será o benchmark [2, 5]; em alta frequência, ruído de microestrutura exige cuidado na escolha da amostragem [48].

2.8 Máxima verossimilhança

Para horizonte T,

$$\ell(\theta) = \sum_k \log \lambda_{c_k}(t_k) - \sum_i \int_0^T \lambda_i(u)\, du.$$

O primeiro termo recompensa intensidade alta nos eventos; o segundo penaliza intensidade alta em todo o intervalo. Maximizar apenas o primeiro faria intensidades tenderem ao infinito. O compensador produz equilíbrio. Para kernel exponencial, a soma sobre o passado obedece a uma recursão de primeira ordem, e ℓ e seu gradiente podem ser calculados em $O(n)$ operações [39]. Sob condições de regularidade, o MLE é consistente e assintoticamente eficiente [36].

2.9 Identificabilidade em amostras finitas

As propriedades assintóticas não garantem bom comportamento com 1.000 eventos. Quando a excitação é fraca ($\alpha_{\text{self}} + \alpha_{\text{cross}}$ pequeno), o kernel quase não altera a intensidade, e a verossimilhança fica plana na direção de β: valores muito diferentes de β explicam os

dados quase igualmente bem. No limite $\alpha \to 0$, β deixa de ser identificado. Perto da criticidade, a separação entre μ e g também se deteriora, pois a taxa média $2\mu/(1-g)$ é bem determinada, mas cada fator isoladamente não é. Esses efeitos reaparecem nos resultados do Capítulo 6.

2.10 Estimação amortizada como estimador de Bayes

Na abordagem de Lee [28], uma rede f_ϕ é treinada com pares (θ_i, x_i), em que θ_i é sorteado de uma distribuição de treino π e x_i é simulado do modelo com parâmetro θ_i. Minimizar o erro quadrático médio,

$$\min_{\phi} \; \mathbb{E}_{\theta\sim\pi}\, \mathbb{E}_{x|\theta} \Big\| f_\phi(x) - \theta \Big\|^2,$$

é minimizar o risco de Bayes sob perda quadrática, cuja solução é a média a posteriori $\mathbb{E}_\pi[\theta \mid x]$ [31]. Logo, uma rede bem treinada aproxima um estimador de Bayes sob o prior π [32, 42]. Duas consequências orientam este trabalho. Primeiro, no teste sorteado do mesmo π, nenhum estimador tem menor MSE médio que a média a posteriori, de modo que superar o MLE nesse teste é esperado e não prova superioridade em sentido frequentista. Segundo, a rede não extrapola: suas estimativas encolhem para a região de alta densidade de π, e dados reais fora do suporte do prior produzem estimativas viesadas.

2.11 LSTM

Redes recorrentes atualizam um estado $h_t = f(x_t, h_{t-1})$. LSTM introduz portas de entrada, esquecimento e saída para controlar fluxo de informação e reduzir o problema de gradientes [25]. Em Lee, a sequência contém interchegada e tipo; o estado final alimenta a regressão dos quatro parâmetros. O artigo também testou GRU [11], com resultado ligeiramente inferior.

2.12 Atenção e Transformer

Atenção calcula combinações ponderadas:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

Cada posição consulta todas as outras. Transformer combina múltiplas cabeças, feed-forward, resíduos e normalização [46]. A vantagem potencial é capturar dependências distantes; o custo potencial é memória $O(n^2)$. A posição da normalização em relação aos resíduos afeta a estabilidade do treino: a variante *post-LN*, usada aqui, costuma exigir aquecimento da taxa de aprendizado [47].

Capítulo 3

Trabalhos relacionados

3.1 Processos de Hawkes em finanças

Depois da formulação original [21, 22], modelos auto e mutuamente excitantes passaram a descrever eventos de mercado em tempo contínuo [9, 17], contágio entre mercados [1] e endogeneidade, medida pela razão de ramificação [18, 20]. Bacry et al. [3] usam um Hawkes bidimensional de altas e baixas para reproduzir o ruído de microestrutura do preço; a excitação cruzada captura a reversão em escalas curtas. Bacry et al. [4] e Hawkes [23] revisam esse campo, e Muni Toke [35] oferece uma introdução didática. Lee and Seo [30] conectam o Hawkes marcado ao preço em ticks e derivam a volatilidade de Hawkes, aplicada a preços filtrados por Lee [29]. No Brasil, Primo [40] analisa o agrupamento intradiário de ações com MLE, e Silva [44] sistematiza inferência, diagnósticos e aplicações financeiras.

3.2 Estimação de processos de Hawkes

O MLE para kernels exponenciais remonta a Ozaki [39], com propriedades assintóticas estabelecidas por Ogata [36]. A simulação por *thinning* [37] e o diagnóstico por resíduos reescalados [10, 38] completam a caixa de ferramentas clássica [27]. A otimização é sensível à inicialização e à geometria da verossimilhança, que pode ser quase plana em algumas direções quando a série é curta (Seção 2.9).

3.3 Inferência amortizada e baseada em simulação

Quando a verossimilhança é cara ou intratável, redes treinadas em simulações substituem a otimização por uma passagem direta [12]. Redes treinadas em simulações já estimam parâmetros de modelos espaciais e de valores extremos [19, 32]; com perda quadrática, elas aproximam estimadores de Bayes [42], e métodos como BayesFlow aprendem a posterior inteira [41]. Lee [28] aplica a ideia ao Hawkes 2D com uma LSTM. Lambe et al. [26] usam redes para o Hawkes observado apenas por contagens em intervalos, caso em que a verossimilhança exata é intratável e o MLE deixa de ser uma alternativa direta.

3.4 Processos pontuais neurais

Outra linha usa redes para modelar a própria intensidade, sem a forma paramétrica de Hawkes: RMTPP [15], o Neural Hawkes Process [34] e variantes com atenção, como o Transformer Hawkes Process [50] e o Self-Attentive Hawkes Process [49]; Shchur et al. [43] revisam a área. O objetivo é diferente do deste trabalho: esses modelos maximizam verossimilhança preditiva, enquanto aqui a rede estima os quatro parâmetros interpretáveis de um modelo clássico.

3.5 Hawkes em criptoativos

Com retornos de um minuto de 17 criptomoedas negociadas na Binance, Taddeo et al. [45] mostram que o Hawkes descreve melhor que o Poisson a ocorrência de saltos nos log-retornos. O mercado de cripto também apresenta segmentação e arbitragem limitada entre bolsas [33], e os futuros perpétuos, sem vencimento e com taxa de financiamento, concentram grande parte da liquidez [24].

3.6 Posicionamento

O presente trabalho combina reprodução controlada, dados públicos de cripto e comparação com atenção, e acrescenta à avaliação de Lee [28] métricas robustas, testes pareados e a leitura da rede como estimador de Bayes.

Tabela 3.1: Posicionamento do trabalho em relação à literatura próxima.

Trabalho	Estimação	Arquitetura	Mercado
Bacry et al. [3]	MLE	–	futuros (Bund, DAX)
Lee and Seo [30]	MLE	–	ações
Primo [40]	MLE	–	ações (Brasil)
Taddeo et al. [45]	MLE	–	cripto (saltos em retornos de 1 min)
Lee [28]	rede	LSTM	ações (EUA)
Lambe et al. [26]	rede	MLP	sintético (contagens)
Zuo et al. [50]	intensidade neural	Transformer	genérico
Este trabalho	rede e MLE	LSTM e Transformer	cripto (futuros perpétuos)

Capítulo 4

Dados

4.1 Fonte e mercado

Foram avaliados spot e futuros. A necessidade de melhor bid/ask eliminou o acervo spot oficial, que não possui bookTicker histórico equivalente. Futuros USD-M fornecem bookTicker e aggTrades. Os símbolos são BTCUSDT e ETHUSDT [6].

4.2 Schema

bookTicker inclui identificador, melhores preços e quantidades de compra e venda, tempo de transação e tempo de evento. O schema canônico possui timestamp UTC, bid, ask e quantidades. Auditorias verificam preço positivo, bid menor ou igual a ask, ordenação e duplicidade temporal.

4.3 Amostragem

Atualizações podem ocorrer a cada milissegundo, muito acima da escala escolhida. Agrupam-se timestamps em bins de 100 ms e mantém-se o último estado. Esse filtro segue o protocolo de Lee e reduz ruído de ultra-alta frequência.

Tabela 4.1: Cobertura dos datasets.

Janela	Dias-símbolo	Eventos	Segmentos de 1.000
Principal (jan. 2024)	28	1.826.904	1.813
Robustez (out. 2023)	14	1.288.352	1.281

4.4 Datasets produzidos

4.5 Características dos eventos

A Tabela 4.2 resume os eventos do bloco de calibração (15 a 22 de janeiro de 2024). Três fatos distinguem esses dados do cenário de Lee [28]. Primeiro, cerca de 76% das mudanças repetem a direção da anterior, o que indica persistência, e não reversão. Segundo, a mediana do salto é de 10 a 15 ticks e só 10–13% dos saltos têm um tick: na escala de 100 ms, esses contratos se comportam como ativos de tick pequeno. Terceiro, 37–39% das interchegadas são exatamente 0,1 s, o passo da grade; a amostragem discretiza fortemente os tempos, enquanto o modelo e as simulações supõem tempo contínuo.

Tabela 4.2: Características dos eventos de mid-price, 15 a 22 de janeiro de 2024.

	BTCUSDT	ETHUSDT
Eventos	529.278	540.164
Fração de altas	49,4%	49,5%
Probabilidade de repetir a direção anterior	76,0%	75,7%
Interchegada mediana	0,3 s	0,3 s
Interchegadas iguais a 0,1 s (grade)	39,5%	37,3%
Salto mediano / percentil 90 (ticks)	15,5 / 48	10 / 29
Saltos de um tick	9,7%	12,6%

Capítulo 5

Metodologia

5.1 Princípios

O protocolo separa:

R1: informação explicitamente publicada;

R2: reconstrução para preencher lacuna;

A1: adaptação necessária para cripto;

E1: extensão com Transformer.

5.2 Pipeline

1. construir URL diária e baixar ZIP;
2. calcular SHA-256 e registrar manifesto;
3. extrair temporariamente o CSV;
4. processar chunks de um milhão de linhas;
5. reduzir atualizações à grade de 100 ms;
6. produzir Parquet particionado por símbolo e data;
7. apagar CSV temporário;
8. criar janelas sem atravessar splits;
9. ajustar MLE e calibrar faixas apenas no treino;
10. gerar trajetórias sintéticas e treinar estimadores;
11. selecionar hiperparâmetros na validação;
12. abrir teste uma única vez.

5.3 Simulação por thinning

Com estado atual, calcula-se um limite para a soma das intensidades. Sorteia-se espera exponencial; a excitação decai; aceita-se o candidato proporcionalmente à nova intensidade [37]. O tipo é sorteado proporcionalmente a λ_1, λ_2. Após o evento, adiciona-se a coluna correspondente da matriz α. Cada trajetória começa com histórico vazio, a mesma hipótese da verossimilhança.

5.4 MLE restrito

Parâmetros positivos são obtidos por softplus. Em vez de otimizar β livremente, usa-se margem positiva d:

$$(\mu, \alpha_s, \alpha_c, d) = \text{softplus}(z), \qquad \beta = \alpha_s + \alpha_c + d.$$

L-BFGS-B é iniciado em cinco pontos: a taxa empírica de eventos e quatro perturbações aleatórias no espaço irrestrito. O MLE nunca recebe o parâmetro verdadeiro como inicialização. O gradiente é analítico, e as recorrências exponenciais são resolvidas como sistemas bidiagonais. Registram-se convergência, iterações, log-verossimilhança e tempo.

5.5 Protocolo neural

O alvo é $(\mu, \alpha_s, \alpha_c, \beta)$, e a perda é o MSE na escala original. A entrada de cada evento é $(\log(1 + \Delta t), s)$, com $s = +1$ para alta e $s = -1$ para baixa; Lee usa interchegadas e tipos 1/2, de modo que essa transformação é uma reconstrução (R2). As duas redes compartilham a cabeça de saída: softplus produz $\mu, \alpha_s, \alpha_c, d > 0$ e $\beta = \alpha_s + \alpha_c + d$, o que garante $g < 1$ por construção, como na versão robusta de Lee.

O experimento sintético congelado contém 75.000 sequências de treino, 10.000 de validação e 15.000 de teste, exclusivamente com 1.000 eventos. Os parâmetros são sorteados com $\mu \in [0{,}2;\ 0{,}6]$, $\beta \in [0{,}8;\ 2{,}0]$, fração autoexcitada $\alpha_s/(\alpha_s + \alpha_c) \in [0{,}2;\ 0{,}8]$ e g balanceado em três estratos: baixo $[0{,}10;\ 0{,}35)$, intermediário $[0{,}35;\ 0{,}70)$ e quase crítico $[0{,}70;\ 0{,}95]$. A Tabela 5.1 resume o treinamento.

O fluxo tensorial do Transformer parte de $[B, L, 2]$, com $L = 1000$. Uma projeção

Tabela 5.1: Configuração e custo do treinamento (cinco seeds por rede, Mac Apple Silicon com MPS).

	LSTM (R1/R2)	Transformer (E1)
Arquitetura	2 LSTM × 12 + densa	encoder, 2 camadas, $d = 32$
Cabeças / feed-forward	–	4 / 128
Parâmetros treináveis	2.068	25.700
Otimizador	Adam, 10^{-3}	Adam, 10^{-3}
Batch efetivo	64	8 (físico 4 com acumulação)
Épocas máximas / paciência	300 / 30	300 / 30
Melhor época (por seed)	165, 164, 193, 239, 299	73, 42, 38, 60, 44
Tempo de treino por seed	5,4–14,8 h	16,6–28,8 h
Tempo total (5 seeds)	41 h	110 h

linear produz $[B, L, 32]$, à qual se soma o encoding posicional. Em cada camada, as quatro cabeças operam em subespaços de dimensão oito; o bloco feed-forward expande 32 para 128 e retorna a 32. A média temporal converte $[B, L, 32]$ em $[B, 32]$. O custo de memória da atenção cresce quadraticamente com L, razão pela qual seu batch é menor que o da LSTM. Essa diferença de batch, sem busca de hiperparâmetros para nenhuma das redes, é uma limitação da comparação.

5.6 Ponto fixo do artigo (E2)

Para comparar diretamente com a tabela de distribuição amostral de Lee [28], foram simuladas 2.000 trajetórias de 1.000 eventos no ponto publicado $(\mu, \alpha_s, \alpha_c, \beta) = (0{,}3;\ 0{,}4;\ 0{,}7;\ 1{,}5)$, que está dentro do prior de treino. As redes foram aplicadas sem retreino, e o MLE foi ajustado em duas versões: a heurística do protocolo e a inicialização no valor verdadeiro usada no artigo.

5.7 Métricas e testes

São reportados MSE por parâmetro e agregado, erro absoluto mediano, viés, validade, erro da razão de ramificação, custo e convergência do MLE. Como os parâmetros têm escalas diferentes, também se reporta o R^2 de cada parâmetro em relação à média do prior (o estimador trivial). A comparação entre redes usa duas fontes de variação: entre seeds (teste de Welch e de Mann–Whitney com cinco seeds), que mede a variabilidade do

treinamento [8], e entre trajetórias do teste (diferença pareada com IC *bootstrap* e teste de Wilcoxon), que mede a precisão dos modelos já treinados [14, 16].

Capítulo 6

Resultados

6.1 Gate de dados

Todos os 56 arquivos principais existiam. Foram geradas 28 partições. BTCUSDT produziu 887.803 eventos; ETHUSDT, 939.101. A janela independente gerou 1.288.352 eventos. O gate de disponibilidade e volume foi, portanto, satisfeito.

6.2 Reprodução no ponto fixo

Tabela 6.1: Distribuição amostral no ponto fixo de Lee [28] ($\mu = 0{,}3$, $\alpha_{\text{self}} = 0{,}4$, $\alpha_{\text{cross}} = 0{,}7$, $\beta = 1{,}5$): média e desvio-padrão em 2.000 trajetórias de 1.000 eventos. As linhas de Lee usam 100.000 trajetórias de 2.000 passos.

	μ		α_{self}		α_{cross}		β	
Estimador	Média	DP	Média	DP	Média	DP	Média	DP
LSTM (ensemble de 5 seeds)	0,3044	0,0365	0,4950	0,0536	0,6245	0,0608	1,5318	0,1436
Transformer (ensemble de 5 seeds)	0,2957	0,0388	0,5280	0,0561	0,6055	0,0620	1,5308	0,1541
MLE heurístico (5 inícios)	0,3065	0,0370	0,3956	0,0728	0,7075	0,0859	1,5156	0,1642
MLE oráculo (início no verdadeiro)	0,3065	0,0370	0,3956	0,0728	0,7075	0,0859	1,5156	0,1642
Lee (2023) rede	0,3151	0,0358	0,4429	0,0661	0,5733	0,0697	1,5736	0,1364
Lee (2023) MLE	0,3036	0,0314	0,3988	0,0500	0,7024	0,0608	1,5078	0,1145

A Tabela 6.1 reproduz o padrão qualitativo de Lee [28]. O MLE é praticamente não viesado, e seus desvios-padrão são cerca de $\sqrt{2}$ vezes os do artigo, o esperado para trajetórias com metade do comprimento. As redes têm o viés característico de encolhimento: aproximam α_{self} e α_{cross} do centro do prior, como no artigo, em troca de menor variância. As duas versões do MLE produziram exatamente as mesmas estimativas, de modo que a inicialização no valor verdadeiro usada por Lee não explica a vantagem do MLE nesse

ponto bem identificado ($g \approx 0{,}73$). O MSE macro foi 0,0103 para o MLE e 0,0111 para o ensemble da LSTM.

6.3 Comparação final: LSTM, Transformer e MLE

Resultados da execução final otimizada

O protocolo final usa exclusivamente trajetórias de 1.000 eventos, com 75.000 amostras de treino, 10.000 de validação e 15.000 de teste. As redes são resumidas sobre cinco seeds independentes; o MLE é ajustado separadamente em cada trajetória do mesmo conjunto de teste. Os intervalos das redes usam a distribuição t de Student entre seeds.

Tabela 6.2: Métricas agregadas no teste sintético congelado (15.000 trajetórias de 1.000 eventos).

Estimador	MSE macro	IC 95%	MAE macro	MSE de g	Validade
LSTM	0,019618	[0,013252; 0,025984]	0,094276	0,001825	100,00%
Transformer	0,023700	[0,019128; 0,028272]	0,105642	0,002138	100,00%
MLE	0,506193	–	0,111852	0,002344	100,00%

Tabela 6.3: MSE de teste por parâmetro (redes: média de cinco seeds).

Estimador	μ	α_{self}	α_{cross}	β
LSTM	0,002296	0,016222	0,016566	0,043386
Transformer	0,002366	0,020905	0,021196	0,050332
MLE	0,010108	0,006146	0,006214	2,002303

Tabela 6.4: MSE macro por regime da razão de ramificação g.

Estimador	g baixo	g intermediário	g quase crítico
LSTM	0,019941	0,015614	0,023297
Transformer	0,022228	0,018964	0,029908
MLE	1,480568	0,016795	0,021214

Entre as redes, a LSTM obteve MSE macro médio 17,2% menor que o Transformer. Com 5 e 5 seeds, porém, a diferença não é estatisticamente significativa (teste de Welch, $p = 0,19$), e os intervalos de confiança se sobrepõem; os dados não permitem ordenar as

redes. A comparação deve considerar conjuntamente erro, estabilidade entre seeds e custo de inferência, e não apenas a melhor seed isolada.

No MLE, o parâmetro β respondeu por 98,9% da soma dos erros quadráticos, e o MSE macro no regime de g baixo foi 88,15 vezes o do regime intermediário: com excitação fraca, β é pouco identificado e algumas trajetórias produzem estimativas extremas. Fora desse regime, o MLE é competitivo: no regime intermediário, seu MSE macro foi 0,0168 (LSTM: 0,0156; Transformer: 0,0190) e, no quase crítico, 0,0212 (LSTM: 0,0233; Transformer: 0,0299). O MLE obteve o menor MSE entre os três estimadores em α_{self} e α_{cross}. Portanto, o MSE macro agregado não ordena os estimadores de forma robusta, e convergência numérica não implica boa recuperação paramétrica.

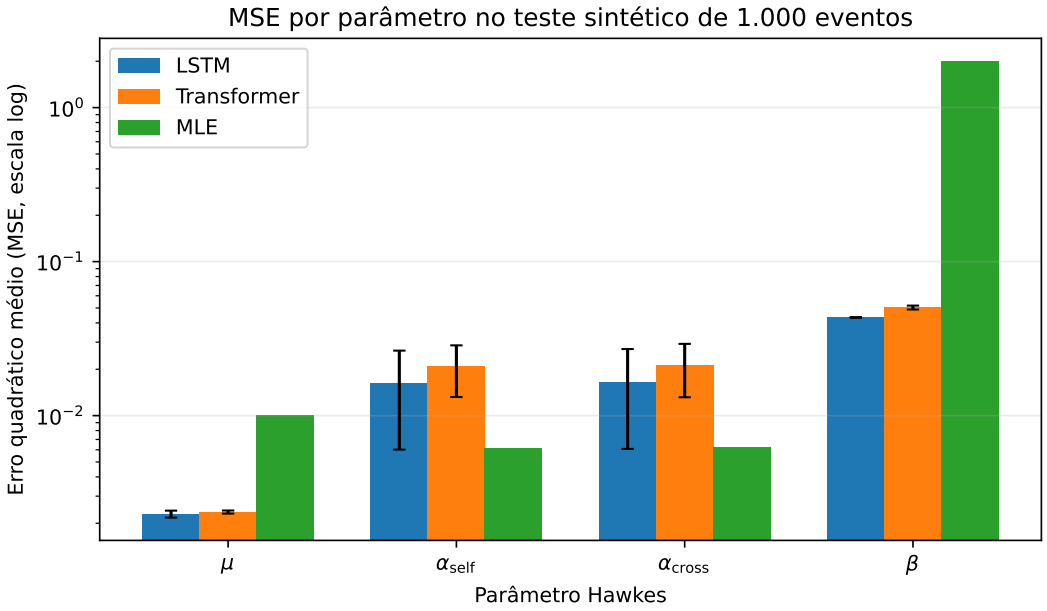


Figura 6.1: MSE de teste por parâmetro no protocolo de 1.000 eventos. As barras de erro das redes representam um desvio-padrão entre seeds.

O MLE convergiu em 100,00% das trajetórias e usou mediana de 14,00 iterações. Todas as comparações usam o mesmo conjunto de teste congelado.

6.4 Análise complementar dos resultados sintéticos

As previsões por trajetória foram recalculadas a partir dos checkpoints congelados (diferença relativa máxima de 10^{-8} em relação ao MSE reportado), sem retreino e sem alterar o protocolo. Como os parâmetros têm escalas diferentes, cada erro quadrático é dividido

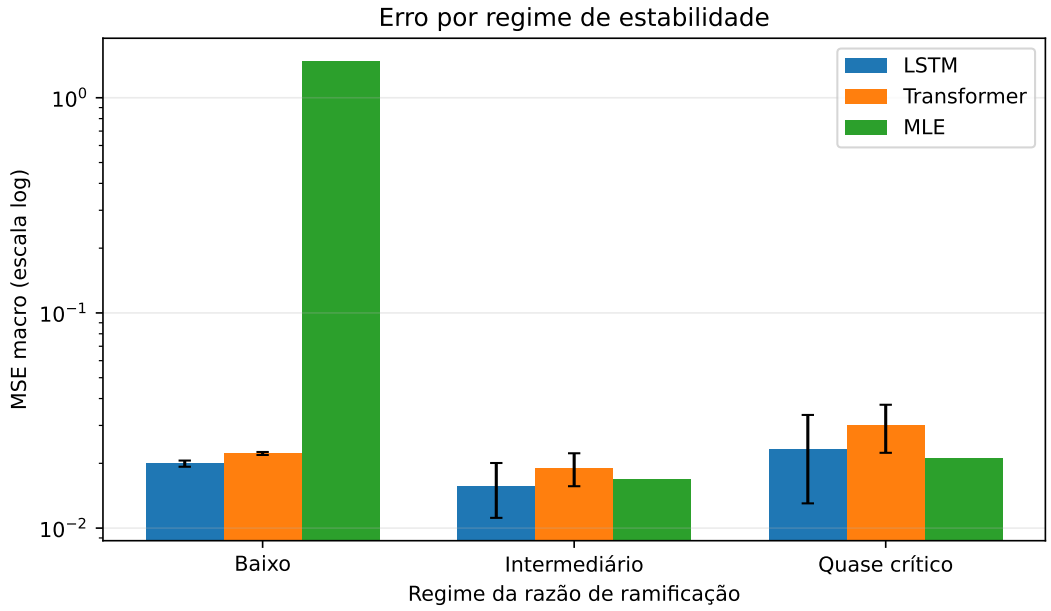


Figura 6.2: MSE macro por regime da razão de ramificação. As barras de erro das redes representam um desvio-padrão entre seeds.

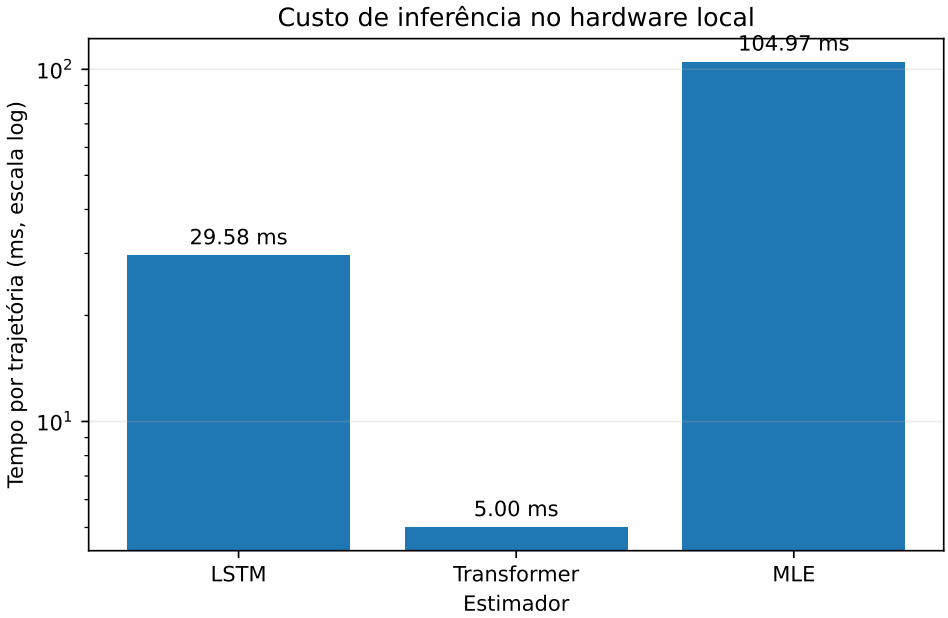


Figura 6.3: Custo por trajetória registrado durante a execução final, em escala logarítmica. Para o MLE, tempo de parede com quatro processos que concorriam com o treino na GPU; para as redes, latência mediana em batch unitário no MPS. Um benchmark controlado posterior mediu cerca de 10 ms por trajetória para o MLE em um único núcleo e deve ser preferido a esta figura.

pela variância do parâmetro no conjunto de treino; o resultado complementar é o R^2 em relação ao estimador trivial que sempre prevê a média a priori.

Tabela 6.5: R^2 por parâmetro em relação à média a priori, erro absoluto mediano macro e MSE da razão de ramificação no teste sintético.

Estimador	μ	α_{self}	α_{cross}	β	EA mediano	MSE de g
Média a priori	−0,01	0,00	−0,01	0,01	0,1908	0,0670
MLE	0,24	0,90	0,90	−15,64	0,0674	0,0023
LSTM (ensemble)	0,84	0,82	0,81	0,65	0,0680	0,0017
Transformer (ensemble)	0,84	0,74	0,73	0,61	0,0765	0,0019

Tabela 6.6: Comparação pareada por trajetória (erro quadrático padronizado médio nos quatro parâmetros). Colunas: perda mediana de A e de B, fração de trajetórias em que A erra menos e IC 95% *bootstrap* da diferença média A−B (negativo favorece A).

A × B	Regime	Med. A	Med. B	A melhor	IC 95% (A−B)
LSTM × Transformer	todos	0,151	0,187	70,2%	[−0,051; −0,047]
LSTM × Transformer	g baixo	0,112	0,131	61,1%	[−0,021; −0,016]
LSTM × Transformer	g intermediário	0,127	0,164	72,8%	[−0,045; −0,041]
LSTM × Transformer	g quase crítico	0,237	0,304	76,7%	[−0,089; −0,081]
LSTM × MLE	todos	0,151	0,149	48,8%	[−9,394; −0,809]
LSTM × MLE	g baixo	0,112	0,199	63,5%	[−26,977; −2,225]
LSTM × MLE	g intermediário	0,127	0,100	40,1%	[−0,040; −0,009]
LSTM × MLE	g quase crítico	0,237	0,183	42,7%	[−0,467; −0,277]
Transformer × MLE	todos	0,187	0,149	43,5%	[−9,376; −0,782]
Transformer × MLE	g baixo	0,131	0,199	59,4%	[−27,686; −2,207]
Transformer × MLE	g intermediário	0,164	0,100	34,2%	[0,002; 0,035]
Transformer × MLE	g quase crítico	0,304	0,183	36,7%	[−0,374; −0,195]

Três conclusões decorrem dessas tabelas. Primeiro, a vantagem das redes sobre o MLE no MSE agregado vem de poucas trajetórias: 94,4% da soma dos erros quadráticos de β do MLE se concentra em 1% das trajetórias, quase todas no regime de g baixo. Em todas as 300 piores, a log-verossimilhança no estimador supera a do parâmetro verdadeiro (ganho mediano de 2,80), e reajustar 100 delas com 20 inícios praticamente não altera o resultado. Não é falha numérica: com excitação fraca, β é pouco identificado em 1.000 eventos. Segundo, na trajetória típica o MLE é tão bom quanto as redes ou melhor: a perda mediana é praticamente igual à da LSTM no agregado e menor nos regimes intermediário e quase crítico. Terceiro, na comparação pareada o ensemble LSTM supera o ensemble Transformer em todos os regimes; entre seeds isoladas, contudo, a diferença não

é significativa (Welch, $p = 0,19$; Mann–Whitney, $p = 0,056$), porque a LSTM apresentou dois níveis de convergência entre seeds.

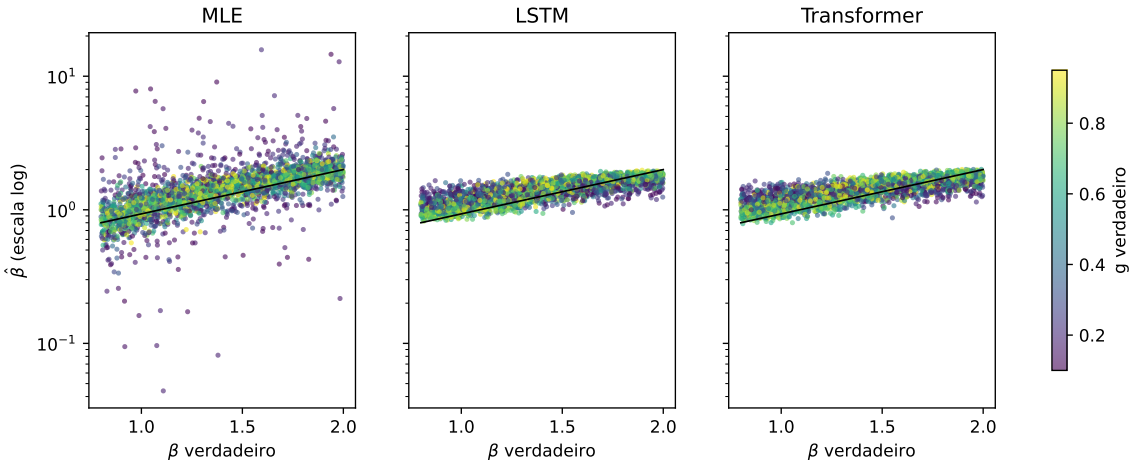


Figura 6.4: β verdadeiro versus estimado (3.000 trajetórias de teste, escala logarítmica). As redes encolhem as estimativas para o centro do prior; o MLE é não viesado na maior parte do domínio, mas produz valores extremos quando g é baixo.

6.5 Calibração empírica e suporte do prior sintético

O MLE foi ajustado nas 1063 janelas de 1.000 eventos do bloco `calibration_train` (15 a 22 de janeiro de 2024), único bloco autorizado para calibração. A mediana de β foi 2,71 (intervalo interquartil 2,21–3,14), acima do limite de 2,0 usado no treino, e α_{cross} ficou abaixo de 10^{-3} em 89,4% das janelas. Apenas 15,4% das janelas têm β dentro do prior, 0,4% têm a fração autoexcitada dentro de [0,2; 0,8] e 0,0% satisfazem todas as faixas ao mesmo tempo. Como um estimador treinado com perda quadrática aproxima a média a posteriori sob o prior de treino, as redes atuais não podem produzir estimativas nessa região; a avaliação empírica exige recalibrar o prior ou treinar com rótulos MLE em janelas reais.

6.6 Custo computacional

A execução final registrou 105 ms de parede por trajetória para o MLE com quatro processos. Esse valor foi medido enquanto o treino neural ocupava a GPU. Um benchmark controlado na mesma máquina, com o mesmo código (que reproduz exatamente as 15.000 estimativas registradas), obteve os valores da Tabela 6.7.

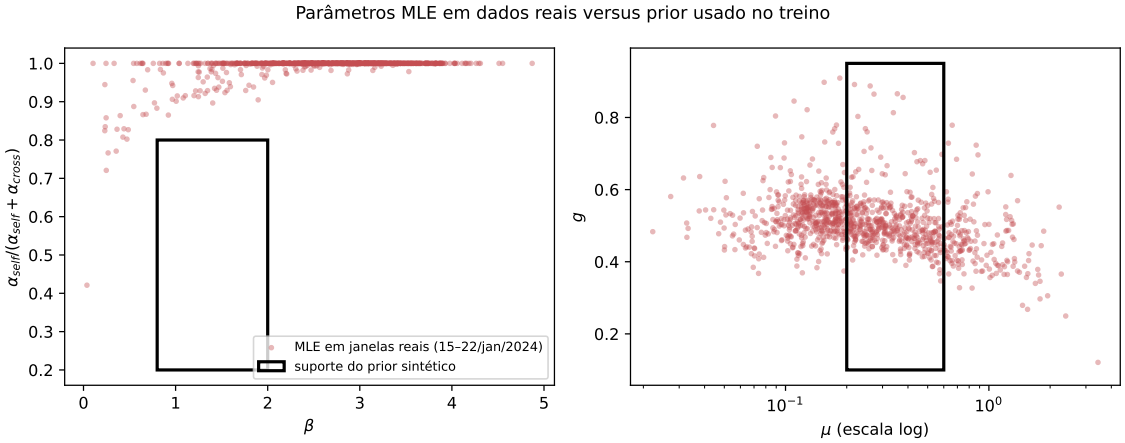


Figura 6.5: Estimativas MLE nas janelas reais de calibração (pontos) e suporte do prior usado para gerar os dados de treino (retângulos).

Tabela 6.7: Custo por trajetória de 1.000 eventos em benchmark controlado.

Estimador e modo de execução	Tempo por trajetória
MLE, 5 inícios, um núcleo	9,6 ms
MLE, 1 início, um núcleo	2,2 ms
MLE, 5 inícios, 4 processos (parede)	2,5 ms
LSTM, lote unitário, CPU (1 thread) / MPS	7,0 ms / 29,6 ms
Transformer, lote unitário, CPU (1 thread / 10 threads) / MPS	9,9 / 4,8 / 5,0 ms
LSTM, lote de 256 no MPS	0,07 ms
Transformer, lote de 32 no MPS	3,7 ms
Lee [28]: rede / MLE	12 ms / 1.763 ms

Com gradiente analítico e recursão linear, o MLE desse modelo de quatro parâmetros custa poucos milissegundos, a mesma ordem da inferência neural em lote unitário. A razão de cerca de 150 vezes reportada por Lee não se repete. A vantagem de custo das redes aparece na inferência em lote, sobretudo para a LSTM, e cresceria em modelos com verossimilhança mais cara.

6.7 Calibração empírica

O MLE nas 1.063 janelas de calibração convergiu em todas. Os detalhes estão na Seção 6.5: a excitação cruzada é praticamente nula, β supera o limite do prior na maior parte das janelas e nenhuma janela cai dentro de todas as faixas usadas no treino.

Capítulo 7

Discussão

7.1 Avaliação das hipóteses

H1 — suportada quanto a estrutura e volume. Os dados públicos permitem reconstruir sequências com a mesma estrutura das de Lee, em volume suficiente. Seu conteúdo estatístico, porém, difere do de ações: direção persistente, saltos de vários ticks e tempos discretizados pela grade (Seção 4.5).

H2 — parcialmente suportada. O erro da LSTM é da mesma ordem do MLE: no ponto fixo, 0,0111 contra 0,0103; no teste sintético, a perda mediana por trajetória é praticamente igual. A latência substancialmente menor não se confirmou em lote unitário frente a um MLE eficiente (Seção 6.6); ela vale para inferência em lote.

H3 — não suportada no sintético. O Transformer não reduziu o erro: o MSE macro médio foi maior que o da LSTM, sem significância entre seeds, e o ensemble Transformer perdeu para o ensemble LSTM em todos os regimes. Ele também não se saiu melhor no regime quase crítico, em que a memória longa seria mais relevante. Sua vantagem foi a latência no MPS (5 ms contra 30 ms da LSTM), ao custo de treino 2,7 vezes maior. O resultado vale para a configuração testada; não houve busca de hiperparâmetros, e o Transformer *post-LN* foi treinado sem aquecimento da taxa de aprendizado.

7.2 Por que as redes vencem no MSE agregado

O MSE macro do MLE (0,506) é cerca de 25 vezes o das redes, mas essa diferença decorre de dois mecanismos, e não de maior precisão das redes na trajetória típica. O primeiro é a

identificabilidade (Seção 2.9): no regime de g baixo, o MLE produz valores extremos de β que maximizam legitimamente a verossimilhança, e 1% das trajetórias concentra 94% do erro quadrático de β. O segundo é o prior (Seção 2.10): as redes aproximam a média a posteriori sob o prior de treino e nunca saem do intervalo [0,8; 2,0] de β, o que limita seu pior erro. Essa robustez é real e útil, mas é comprada com viés de encolhimento e depende de o prior representar os dados.

7.3 Comparação com Lee (2023)

As conclusões qualitativas de Lee se mantêm: a rede atinge erro da mesma ordem do MLE, com viés de encolhimento, e o MLE é quase não viesado quando o parâmetro é bem identificado. Os valores absolutos de MSE não são comparáveis entre os trabalhos, pois dependem das faixas de parâmetros, que o artigo não publica. Duas divergências merecem registro: o ganho de velocidade de duas ordens de grandeza não se repete com um MLE eficiente, e a avaliação apenas por MSE agregado esconde as falhas de identificabilidade que a inicialização no valor verdadeiro tende a mascarar.

7.4 Implicações para a etapa empírica

Os parâmetros estimados em janelas reais ($\alpha_{\text{cross}} \approx 0$, $\beta \approx 2{,}7$) ficam fora do suporte do prior de treino, e as redes atuais encolheriam suas estimativas para dentro desse suporte. A excitação cruzada nula contrasta com o ponto típico de ações, em que ela domina (no ponto fixo de Lee, $\alpha_{\text{cross}} > \alpha_{\text{self}}$), e é coerente com a persistência de direção medida nos dados. Antes de qualquer comparação empírica, portanto, é preciso recalibrar o prior com as janelas de calibração, ou treinar com rótulos MLE em janelas reais, como sugere Lee [28]. A discretização em 100 ms indica uma terceira via: simular e filtrar na mesma grade, caso em que o MLE de tempo contínuo fica mal especificado e a estimação amortizada ganha vantagem estrutural [26].

7.5 Ameaças à validade

- **Interna:** vazamento por janelas sobrepostas; tuning após observar o teste. Mitigadas por splits cronológicos e teste fechado por flag.

- **Construto:** o MLE pode ser rótulo imperfeito sob má especificação; nas janelas reais, α_{cross} fica na fronteira do espaço de parâmetros, em que a teoria assintótica usual não vale.
- **Prior:** as métricas sintéticas dependem das faixas sorteadas, que não foram calibradas nos dados.
- **Externa:** dois ativos e duas janelas não representam todo o mercado.
- **Estatística:** cinco seeds quantificam apenas parte da variabilidade de treino; a LSTM apresentou dois níveis de convergência entre seeds, e uma seed atingiu o limite de 300 épocas ainda melhorando.
- **Reprodução:** o artigo omite faixas, seeds e detalhes de treino.
- **Computacional:** latência depende de hardware, lote, aquecimento e concorrência entre processos.

Capítulo 8

Trabalhos futuros

1. treinar as redes com rótulos MLE em janelas reais de calibração, selecionar na validação, abrir o teste empírico uma única vez e avaliar outubro com checkpoints congelados;
2. recalibrar o prior sintético pelas janelas de calibração e retreinar;
3. diagnosticar o ajuste nos dados reais por resíduos reescalados [10, 38] e comparar com Poisson e com variantes do modelo;
4. simular e filtrar na grade de 100 ms, para estimar sob a mesma observação dos dados reais;
5. calcular volatilidade Hawkes e compará-la à realized volatility;
6. padronizar os alvos, buscar hiperparâmetros e aquecer a taxa de aprendizado do Transformer, sem reutilizar o teste sintético para ajuste;
7. adequar o documento ao modelo de TG do ITA.

Capítulo 9

Conclusão

O trabalho construiu uma pipeline reproduzível que vai dos dados públicos da Binance até a comparação de três estimadores sob protocolo congelado, e reproduziu o padrão qualitativo de Lee [28] no ponto fixo publicado. No teste sintético, a LSTM não perdeu para o Transformer, e a atenção não trouxe ganho de precisão. A vantagem das redes sobre o MLE no MSE agregado vem da robustez nas trajetórias em que β é mal identificado e do encolhimento para o prior; na trajetória típica, o MLE é igualmente preciso e, com implementação eficiente, igualmente rápido em lote unitário. A etapa empírica mostrou que os dados de cripto ocupam outra região do espaço de parâmetros, com excitação cruzada nula, o que torna a recalibração do prior condição para aplicar as redes. A geração automática de tabelas e figuras reduz o risco de divergência entre artefatos e texto.

Apêndice A

Ambiguidades de Lee (2023)

O texto menciona caminhos de 2.000 passos, mas uma forma de entrada com 1.000. Não publica as faixas exatas de parâmetros, seeds, batch size nem dados NBBO. Essa menção a 2.000 passos é mantida apenas como contexto histórico da reconstrução. O protocolo final fixa 1.000 eventos e não compara comprimentos; decisões reconstruídas são marcadas R2; cripto, A1; Transformer, E1. O artigo chama de "três camadas" as duas camadas LSTM seguidas da camada densa; a implementação segue essa estrutura. A entrada $\log(1 + \Delta t)$ e a codificação ± 1 da direção também são R2.

Apêndice B

Reprodução computacional

```
uv sync --python 3.13 --extra dev
make test
make synthetic-final      # dados sinteticos com seed e SHA-256
make local-final          # treino retomavel, MLE, consolidacao, figuras e PDFs
make fixed-point          # experimento E2 no ponto fixo de Lee
make posthoc              # calibracao empirica e analise complementar
```

Apêndice C

Histórico de validação da pipeline

Antes do protocolo congelado, testes reduzidos validaram a integração dos componentes. Seus números não são comparáveis aos resultados finais e são registrados apenas para rastreabilidade.

Tabela C.1: Testes de integração anteriores ao protocolo congelado.

Teste	Configuração	Resultado
Sintético reduzido	1.024/128 trajetórias, 128 eventos, 3 épocas	MSE LSTM 0,0448; Transformer 0,0328
Integração empírica	12 janelas rotuladas pelo MLE, só treino	MSE de treino 0,5038 e 0,1800
Protocolo congelado reduzido	48/16/16 trajetórias, 2 épocas	pipeline validada

Referências Bibliográficas

[1] Yacine Aït-Sahalia, Julio Cacho-Diaz, and Roger J. A. Laeven. Modeling financial contagion using mutually exciting jump processes. *Journal of Financial Economics*, 117(3):585–606, 2015. doi: 10.1016/j.jfineco.2015.03.002.

[2] Torben G. Andersen, Tim Bollerslev, Francis X. Diebold, and Paul Labys. Modeling and forecasting realized volatility. *Econometrica*, 71(2):579–625, 2003. doi: 10.1111/1468-0262.00418.

[3] Emmanuel Bacry, Sylvain Delattre, Marc Hoffmann, and Jean-François Muzy. Modelling microstructure noise with mutually exciting point processes. *Quantitative Finance*, 13(1):65–77, 2013. doi: 10.1080/14697688.2011.647054.

[4] Emmanuel Bacry, Iacopo Mastromatteo, and Jean-François Muzy. Hawkes processes in finance. *Market Microstructure and Liquidity*, 1(1):1550005, 2015. doi: 10.1142/S2382626615500057.

[5] Ole E. Barndorff-Nielsen and Neil Shephard. Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 64(2):253–280, 2002. doi: 10.1111/1467-9868.00336.

[6] Binance. Binance Public Data. `https://data.binance.vision` e `https://github.com/binance/binance-public-data`, 2026. Acesso em 31 ago. 2026.

[7] Jean-Philippe Bouchaud, Julius Bonart, Jonathan Donier, and Martin Gould. *Trades, Quotes and Prices: Financial Markets Under the Microscope*. Cambridge University Press, Cambridge, 2018. doi: 10.1017/9781316659335.

[8] Xavier Bouthillier, Pierre Delaunay, Mirko Bronzi, Assya Trofimov, Brennan Nichyporuk, Justin Szeto, Nazanin Mohammadi Sepahvand, Edward Raff, Kanika Madan, Vikram Voleti, Samira Ebrahimi Kahou, Vincent Michalski, Tal Arbel, Chris Pal, Gael Varoquaux, and Pascal Vincent. Accounting for variance in machine learning benchmarks. In A. Smola, A. Dimakis, and I. Stoica, editors, *Proceedings of Machine Learning and Systems*, volume 3, pages 747–769, 2021. URL https://proceedings.mlsys.org/paper_files/paper/2021/hash/0184b0cd3cfb185989f858a1d9f5c1eb-Abstract.html.

[9] Clive G. Bowsher. Modelling security market events in continuous time: intensity based, multivariate point process models. *Journal of Econometrics*, 141(2):876–912, 2007. doi: 10.1016/j.jeconom.2006.11.007.

[10] Emery N. Brown, Riccardo Barbieri, Valérie Ventura, Robert E. Kass, and Loren M. Frank. The time-rescaling theorem and its application to neural spike train data analysis. *Neural Computation*, 14(2):325–346, 2002. doi: 10.1162/08997660252741149.

[11] Kyunghyun Cho, Bart van Merriënboer, Dzmitry Bahdanau, and Yoshua Bengio. On the properties of neural machine translation: encoder–decoder approaches. In Dekai Wu, Marine Carpuat, Xavier Carreras, and Eva Maria Vecchi, editors, *Proceedings of SSST-8, Eighth Workshop on Syntax, Semantics and Structure in Statistical Translation*, pages 103–111, Doha, Qatar, October 2014. Association for Computational Linguistics. doi: 10.3115/v1/W14-4012. arXiv:1409.1259.

[12] Kyle Cranmer, Johann Brehmer, and Gilles Louppe. The frontier of simulation-based inference. *Proceedings of the National Academy of Sciences*, 117(48):30055–30062, 2020. doi: 10.1073/pnas.1912789117.

[13] D. J. Daley and D. Vere-Jones. *An Introduction to the Theory of Point Processes. Volume I: Elementary Theory and Methods*. Probability and Its Applications. Springer, New York, second edition, 2003. doi: 10.1007/b97277.

[14] Francis X. Diebold and Roberto S. Mariano. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263, 1995. doi: 10.1080/07350015.1995.10524599.

[15] Nan Du, Hanjun Dai, Rakshit Trivedi, Utkarsh Upadhyay, Manuel Gomez-Rodriguez, and Le Song. Recurrent marked temporal point processes: embedding event history to vector. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1555–1564. ACM, 2016. doi: 10.1145/2939672.2939875.

[16] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Number 57 in Monographs on Statistics and Applied Probability. Chapman & Hall, New York, 1993. doi: 10.1007/978-1-4899-4541-9.

[17] Paul Embrechts, Thomas Liniger, and Lu Lin. Multivariate Hawkes processes: an application to financial data. *Journal of Applied Probability*, 48A:367–378, 2011. doi: 10.1239/jap/1318940477.

[18] Vladimir Filimonov and Didier Sornette. Quantifying reflexivity in financial markets: toward a prediction of flash crashes. *Physical Review E*, 85(5):056108, 2012. doi: 10.1103/PhysRevE.85.056108.

[19] Florian Gerber and Douglas Nychka. Fast covariance parameter estimation of spatial Gaussian process models using neural networks. *Stat*, 10(1):e382, 2021. doi: 10.1002/sta4.382.

[20] Stephen J. Hardiman, Nicolas Bercot, and Jean-Philippe Bouchaud. Critical reflexivity in financial markets: a Hawkes process analysis. *The European Physical Journal B*, 86(10):442, 2013. doi: 10.1140/epjb/e2013-40107-3.

[21] Alan G. Hawkes. Spectra of some self-exciting and mutually exciting point processes. *Biometrika*, 58(1):83–90, 1971. doi: 10.1093/biomet/58.1.83.

[22] Alan G. Hawkes. Point spectra of some mutually exciting point processes. *Journal of the Royal Statistical Society: Series B (Methodological)*, 33(3):438–443, 1971. doi: 10.1111/j.2517-6161.1971.tb01530.x.

[23] Alan G. Hawkes. Hawkes processes and their applications to finance: a review. *Quantitative Finance*, 18(2):193–198, 2018. doi: 10.1080/14697688.2017.1403131.

[24] Songrun He, Asaf Manela, Omri Ross, and Victor von Wachter. Fundamentals of perpetual futures. arXiv preprint arXiv:2212.06888, 2022. Working paper; latest revision v7, 17 Sep. 2026.

[25] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.

[26] Jason J. Lambe, Feng Chen, Tom Stindl, and Tsz-Kit Jeffrey Kwan. Neural networks for parameter estimation of the discretely observed Hawkes process. *Journal of Computational and Graphical Statistics*, 2026. doi: 10.1080/10618600.2026.2754088. Publicado online em 27 out. 2026; volume e páginas ainda não atribuídos. Preprint: arXiv:2506.01258.

[27] Patrick J. Laub, Young Lee, and Thomas Taimre. *The Elements of Hawkes Processes*. Springer, Cham, 2021. doi: 10.1007/978-3-030-84639-8.

[28] Kyungsub Lee. Recurrent neural network based parameter estimation of Hawkes model on high-frequency financial data. *Finance Research Letters*, 55:103922, 2023. doi: 10.1016/j.frl.2023.103922.

[29] Kyungsub Lee. Application of Hawkes volatility in the observation of filtered high-frequency price process in tick structures. *Applied Stochastic Models in Business and Industry*, 40(6):1689–1711, 2024. doi: 10.1002/asmb.2892.

[30] Kyungsub Lee and Byoung Ki Seo. Marked Hawkes process modeling of price dynamics and volatility estimation. *Journal of Empirical Finance*, 40:174–200, 2017. doi: 10.1016/j.jempfin.2016.08.004.

[31] E. L. Lehmann and George Casella. *Theory of Point Estimation*. Springer Texts in Statistics. Springer, New York, second edition, 1998. doi: 10.1007/b98854.

[32] Amanda Lenzi, Julie Bessac, Johann Rudi, and Michael L. Stein. Neural networks for parameter estimation in intractable models. *Computational Statistics & Data Analysis*, 185:107762, 2023. doi: 10.1016/j.csda.2023.107762.

[33] Igor Makarov and Antoinette Schoar. Trading and arbitrage in cryptocurrency markets. *Journal of Financial Economics*, 135(2):293–319, 2020. doi: 10.1016/j.jfineco.2019.07.001.

[34] Hongyuan Mei and Jason M. Eisner. The neural Hawkes process: a neurally self-modulating multivariate point process. In I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/6463c88460bd63bbe256e495c63aa40b-Abstract.html.

[35] Ioane Muni Toke. An introduction to Hawkes processes with applications to finance. Lecture slides, École Centrale Paris, BNP Paribas Chair of Quantitative Finance, February 2011. Slides dated 4 February 2011.

[36] Yosihiko Ogata. The asymptotic behaviour of maximum likelihood estimators for stationary point processes. *Annals of the Institute of Statistical Mathematics*, 30(2): 243–261, 1978. doi: 10.1007/BF02480216.

[37] Yosihiko Ogata. On Lewis' simulation method for point processes. *IEEE Transactions on Information Theory*, 27(1):23–31, 1981. doi: 10.1109/TIT.1981.1056305.

[38] Yosihiko Ogata. Statistical models for earthquake occurrences and residual analysis for point processes. *Journal of the American Statistical Association*, 83(401):9–27, 1988. doi: 10.1080/01621459.1988.10478560.

[39] T. Ozaki. Maximum likelihood estimation of Hawkes' self-exciting point processes. *Annals of the Institute of Statistical Mathematics*, 31(1):145–155, 1979. doi: 10.1007/BF02480272.

[40] Gabriel Oliveira Primo. Padrão de aglomeração intradiário do mercado de ações brasileiro: análise exploratória com processo de Hawkes. Dissertação (Mestrado em Economia), Programa de Pós-Graduação em Economia, Universidade Federal de Pernambuco, Recife, 2018. URL https://repositorio.ufpe.br/handle/123456789/32068.

[41] Stefan T. Radev, Ulf K. Mertens, Andreas Voss, Lynton Ardizzone, and Ullrich Köthe. BayesFlow: learning complex stochastic models with invertible neural networks. *IEEE Transactions on Neural Networks and Learning Systems*, 33(4):1452–1466, 2022. doi: 10.1109/TNNLS.2020.3042395.

[42] Matthew Sainsbury-Dale, Andrew Zammit-Mangion, and Raphaël Huser. Likelihood-free parameter estimation with neural Bayes estimators. *The American Statistician*, 78(1):1–14, 2024. doi: 10.1080/00031305.2023.2249522.

[43] Oleksandr Shchur, Ali Caner Türkmen, Tim Januschowski, and Stephan Günnemann. Neural temporal point processes: a review. In *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence*, pages 4585–4593. International Joint Conferences on Artificial Intelligence Organization, 2021. doi: 10.24963/ijcai.2021/623.

[44] Lucas Augusto de Oliveira Silva. Processos de Hawkes e aplicações. Dissertação (Mestrado em Matemática Aplicada), Instituto de Matemática, Estatística e Ciência da Computação, Universidade de São Paulo, São Paulo, 2026.

[45] Marcelo Magalhães Taddeo, Leonardo Salvi, and Miguel Angel Rivera-Castro. Sobre o uso de processos de Hawkes para avaliar a frequência de saltos nos log retornos de criptomoedas. *Brazilian Review of Finance*, 22(2):69–92, 2024. doi: 10.12660/rbfin.v22n2.2024.89144.

[46] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[47] Ruibin Xiong, Yunchang Yang, Di He, Kai Zheng, Shuxin Zheng, Chen Xing, Huishuai Zhang, Yanyan Lan, Liwei Wang, and Tieyan Liu. On layer normalization in the Transformer architecture. In Hal Daumé, III and Aarti Singh, editors, *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 10524–10533. PMLR, 2020. URL https://proceedings.mlr.press/v119/xiong20b.html.

[48] Lan Zhang, Per A. Mykland, and Yacine Aït-Sahalia. A tale of two time scales: determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472):1394–1411, 2005. doi: 10.1198/016214505000000169.

[49] Qiang Zhang, Aldo Lipani, Omer Kirnap, and Emine Yilmaz. Self-attentive Hawkes process. In Hal Daumé, III and Aarti Singh, editors, *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 11183–11193. PMLR, 2020. URL https://proceedings.mlr.press/v119/zhang20q.html.

[50] Simiao Zuo, Haoming Jiang, Zichong Li, Tuo Zhao, and Hongyuan Zha. Transformer Hawkes process. In Hal Daumé, III and Aarti Singh, editors, *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 11692–11702. PMLR, 2020. URL https://proceedings.mlr.press/v119/zuo20a.html.