INSTITUTO TECNOLÓGICO DE AERONÁUTICA

João Matheus Del Vecchio

Estimação Neural de Processos de Hawkes em Dados de Criptomoedas de Alta Frequência

Relatório técnico de resultados parciais

São José dos Campos

2026

Resumo

Este relatório registra o estado executado do projeto que reproduz e estende Lee [6]. A contribuição planejada consiste em estimar os parâmetros de um processo de Hawkes bidimensional por redes neurais em dados de alta frequência de BTCUSDT e ETHUSDT. Foram construídos o repositório reproduzível, a ingestão dos dados públicos da Binance, a transformação do top-of-book em eventos, o simulador de Hawkes, o estimador de máxima verossimilhança, a LSTM de referência e o Transformer comparativo. A janela principal, de 15 a 28 de janeiro de 2024, contém 1.826.904 eventos; a janela de robustez, de 23 a 29 de outubro de 2023, contém 1.288.352 eventos. Testes exploratórios confirmaram a integração dos componentes. A avaliação sintética final usa 75.000 trajetórias de treino, 10.000 de validação e 15.000 de teste, todas com 1.000 eventos; LSTM e Transformer são agregados sobre cinco seeds e comparados ao MLE.

Sumário

1 Objetivo e estado do trabalho **1**

2 Dados **2**

2.1 Por que futuros USD-M 2

2.2 Períodos 2

2.3 Transformação 3

2.4 Cobertura principal 3

2.5 Robustez 3

3 Modelo de Hawkes **4**

3.1 Intensidade 4

3.2 Estabilidade 4

4 Métodos implementados **6**

4.1 Simulação 6

4.2 Máxima verossimilhança 6

4.3 LSTM 6

4.4 Transformer 7

5 Resultados exploratórios **8**

5.1 Experimento sintético reduzido 8

5.2 Integração empírica 8

5.3 Validação do protocolo final 9

6 Limitações e riscos **10**

7 Comparação final: LSTM, Transformer e MLE **11**

8 Atualização de 30/10/2026: análise complementar **14**

8.1 Ponto fixo do artigo (E2) 14

8.2 Análise complementar dos resultados sintéticos 15

8.3 Calibração empírica e suporte do prior sintético 16

9 Próximas etapas **18**

A Comandos de reprodução **19**

Capítulo 1

Objetivo e estado do trabalho

O problema é estimar rapidamente

$$\theta = (\mu, \alpha_{\text{self}}, \alpha_{\text{cross}}, \beta)$$

de um processo de Hawkes que representa mudanças para cima e para baixo no preço. A máxima verossimilhança (MLE) é o referencial estatístico; a LSTM de Lee [6] é a reprodução; o Transformer é a extensão.

> **Estado da evidência.** Este documento distingue os smoke tests de integração da avaliação final. As métricas finais são geradas diretamente do resumo consolidado e incorporadas no capítulo de comparação, evitando transcrição manual.

Foram concluídos:

1. a fonte e o mercado foram escolhidos com evidência de disponibilidade;
2. 42 partições diárias foram processadas: 28 principais e 14 de robustez;
3. o Hawkes 2D foi simulado pelo método de Ogata;
4. o MLE foi implementado com restrições de estabilidade;
5. LSTM e Transformer foram executados em cinco seeds no teste sintético congelado;
6. o MLE foi ajustado separadamente nas 15.000 trajetórias desse teste;
7. testes automatizados, lint e verificações dos artefatos foram executados.

Capítulo 2

Dados

2.1 Por que futuros USD-M

O artigo-base usa NBBO de ações, isto é, a melhor oferta de compra e a melhor oferta de venda. Para cripto, era necessário um equivalente. A Binance publica bookTicker histórico para futuros USD-M, contendo melhor bid e ask, mas não oferece o mesmo arquivo histórico oficial para spot. aggTrades existe nos dois mercados, porém negócios realizados não permitem reconstruir sozinhos o top-of-book. Logo, foram escolhidos futuros perpétuos USD-M [3].

2.2 Períodos

Tabela 2.1: Janelas empíricas processadas.

Uso	Período UTC	Símbolos	Produtos
Principal	15–28 jan. 2024	BTCUSDT, ETHUSDT	bookTicker, aggTrades
Robustez	23–29 out. 2023	BTCUSDT, ETHUSDT	bookTicker, aggTrades

O split principal foi congelado temporalmente:

- 15–22 de janeiro: calibração e treino empírico;
- 23–25 de janeiro: validação;
- 26–28 de janeiro: teste fechado.

Janelas sobrepostas não podem cruzar essas fronteiras, pois isso copiaria eventos do treino para validação ou teste.

2.3 Transformação

Para cada atualização:

$$m(t) = \frac{p_{\text{bid}}(t) + p_{\text{ask}}(t)}{2}.$$

O último estado disponível em cada intervalo de 100 ms é mantido. Se o mid-price não muda, não há evento. Se muda, registra-se tipo 1 para alta e tipo 2 para baixa, tempo entre eventos e módulo do salto em ticks. BTCUSDT usa tick 0,1; ETHUSDT, 0,01. O processamento é incremental, pois um único CSV diário pode ter 1,7 GB e quase 20 milhões de linhas.

2.4 Cobertura principal

Tabela 2.2: Resumo do dataset principal após filtragem.

Símbolo	Eventos	Segmentos de 1.000
BTCUSDT	887.803	880
ETHUSDT	939.101	933
Total	1.826.904	1.813

Todos os 56 arquivos esperados estavam disponíveis. Para o comprimento adotado no protocolo final, o índice contém 1.813 janelas de 1.000 eventos. O menor dia ainda contém 16.576 eventos em BTCUSDT e 20.828 em ETHUSDT.

2.5 Robustez

A janela de outubro produziu 652.773 eventos de BTCUSDT e 635.579 de ETHUSDT, totalizando 1.288.352. Ela não foi usada para escolher arquitetura e deverá funcionar como teste de mudança de regime temporal.

Capítulo 3

Modelo de Hawkes

3.1 Intensidade

Para tipos $i, j \in \{1, 2\}$,

$$\lambda_i(t) = \mu + \sum_{j=1}^{2} \sum_{t_k^j < t} \alpha_{ij} \exp[-\beta(t - t_k^j)],$$

com

$$\boldsymbol{\alpha} = \begin{bmatrix} \alpha_{\text{self}} & \alpha_{\text{cross}} \\ \alpha_{\text{cross}} & \alpha_{\text{self}} \end{bmatrix}.$$

Um evento de alta aumenta imediatamente as intensidades; esse aumento decai à taxa β. A autoexcitação mede o efeito sobre o mesmo tipo, e a excitação cruzada mede o efeito sobre o tipo oposto [2, 4].

3.2 Estabilidade

A razão de ramificação do modelo simétrico é

$$g = \frac{\alpha_{\text{self}} + \alpha_{\text{cross}}}{\beta}.$$

Exige-se $g < 1$. Intuitivamente, cada evento precisa gerar, em média, menos de um descendente direto; caso contrário, a cascata não morre. No código, a rede prevê uma

margem positiva d e define

$$\beta = \alpha_{\text{self}} + \alpha_{\text{cross}} + d, \qquad d = \text{softplus}(z_4) > 0.$$

Isso garante a restrição por construção.

Capítulo 4

Métodos implementados

4.1 Simulação

O método de thinning de Ogata [7] gera um tempo candidato a partir de uma intensidade que limita a intensidade futura. O candidato é aceito com probabilidade igual à razão entre intensidade real e limite. Após a aceitação, escolhe-se alta ou baixa proporcionalmente às intensidades e atualiza-se o vetor de excitação.

4.2 Máxima verossimilhança

Para eventos (t_k, c_k) observados até T,

$$\ell(\theta) = \sum_k \log \lambda_{c_k}(t_k) - \sum_{i=1}^{2} \int_0^T \lambda_i(u)\, du.$$

O código usa L-BFGS-B sobre parâmetros não restritos, transformados por softplus. Foram empregados múltiplos pontos iniciais. Os seis ajustes de 1.000 eventos reportados abaixo—dois símbolos e três splits—convergiram.

4.3 LSTM

A réplica possui duas camadas LSTM com 12 unidades e uma camada de saída com quatro valores, conforme Lee [6]. A entrada em cada passo é $(\log(1 + \Delta t), s)$, em que $s = +1$ para alta e $s = -1$ para baixa. A LSTM [5] comprime o histórico em um estado oculto, usado para prever θ.

Tabela 4.1: Tempos dos ajustes MLE de 1.000 eventos.

Símbolo	Data	Split	Convergência	Tempo (s)
BTCUSDT	15 jan.	treino	sim	2,02
BTCUSDT	23 jan.	validação	sim	1,33
BTCUSDT	26 jan.	teste	sim	1,93
ETHUSDT	15 jan.	treino	sim	2,77
ETHUSDT	23 jan.	validação	sim	1,68
ETHUSDT	26 jan.	teste	sim	1,74

4.4 Transformer

O Transformer [8] projeta os dois atributos para dimensão interna, adiciona codificação posicional senoidal, aplica autoatenção e agrega os estados por média. A atenção permite comparar diretamente posições distantes, mas tem custo quadrático no comprimento da sequência.

Na configuração final, cada vetor de dimensão 2 é projetado para $d_{\text{model}} = 32$. O encoding senoidal é somado antes de duas camadas encoder. Cada camada divide os 32 componentes em quatro cabeças de oito componentes, aplica autoatenção e uma rede feed-forward $32 \to 128 \to 32$. Após normalização, a média dos estados ao longo dos 1.000 eventos produz um vetor de dimensão 32. A cabeça softplus retorna $\mu, \alpha_s, \alpha_c, d > 0$ e constrói $\beta = \alpha_s + \alpha_c + d$; logo, $g < 1$ por construção.

Capítulo 5

Resultados exploratórios

5.1 Experimento sintético reduzido

Foram geradas 1.024 trajetórias de treino e 128 de teste, com 128 eventos e três épocas.

Tabela 5.1: Smoke test sintético; não é resultado final.

Modelo	MSE de teste	Inferência (ms/sequência)	Saídas válidas
LSTM	0,0448	0,156	100%
Transformer	0,0328	0,793	100%

O Transformer teve MSE 26,7% menor nessa execução, mas latência aproximadamente 5,1 vezes maior. Não se pode generalizar: o treino publicado por Lee usa 75.000 amostras, teste de 15.000 e geralmente mais de 300 épocas.

5.2 Integração empírica

Doze janelas de 1.000 eventos, rotuladas pelo MLE, foram usadas em um treino mínimo. O MSE de treino foi 0,5038 para LSTM e 0,1800 para Transformer; 100% das saídas foram válidas. Como o valor é de treino e a amostra é minúscula, ele apenas prova que dados reais percorrem toda a pipeline. Não mede generalização.

5.3 Validação do protocolo final

Um segundo smoke test validou o novo runner com shards persistidos, validação, checkpoints, métricas por parâmetro e MLE sem inicialização-oráculo. Ele usou apenas 48/16/16 trajetórias e duas épocas com sequências de 1.000 eventos. Os MSEs foram 0,2286 (LSTM), 0,1176 (Transformer) e 0,0064 (MLE em duas trajetórias). Todas as saídas neurais foram válidas. Esses valores verificam a execução do protocolo; o pequeno orçamento impede qualquer conclusão comparativa.

Capítulo 6

Limitações e riscos

1. Os dados originais de ações de Lee não estão públicos; a parte empírica é adaptação, não reprodução literal.
2. O artigo diverge entre a menção textual ao comprimento da sequência e o tensor reportado; o protocolo final adota exclusivamente sequências de 1.000 eventos.
3. Faixas exatas, seeds, batch size e vários hiperparâmetros não foram publicados.
4. A excitação cruzada do MLE ficou próxima de zero em 89% das 1.063 janelas de calibração, e nenhuma janela cai dentro das faixas usadas no treino sintético (Capítulo 8); a avaliação empírica exige recalibrar o prior.
5. O mercado 24/7 é não estacionário; splits e janela de robustez mitigam, mas não eliminam esse risco.
6. O teste empírico fechado ainda requer avaliação com checkpoints congelados; ele é distinto do teste sintético final reportado neste documento.

Capítulo 7

Comparação final: LSTM, Transformer e MLE

Resultados da execução final otimizada

O protocolo final usa exclusivamente trajetórias de 1.000 eventos, com 75.000 amostras de treino, 10.000 de validação e 15.000 de teste. As redes são resumidas sobre cinco seeds independentes; o MLE é ajustado separadamente em cada trajetória do mesmo conjunto de teste. Os intervalos das redes usam a distribuição t de Student entre seeds.

Tabela 7.1: Métricas agregadas no teste sintético congelado (15.000 trajetórias de 1.000 eventos).

Estimador	MSE macro	IC 95%	MAE macro	MSE de g	Validade
LSTM	0,019618	[0,013252; 0,025984]	0,094276	0,001825	100,00%
Transformer	0,023700	[0,019128; 0,028272]	0,105642	0,002138	100,00%
MLE	0,506193	–	0,111852	0,002344	100,00%

Tabela 7.2: MSE de teste por parâmetro (redes: média de cinco seeds).

Estimador	μ	α_{self}	α_{cross}	β
LSTM	0,002296	0,016222	0,016566	0,043386
Transformer	0,002366	0,020905	0,021196	0,050332
MLE	0,010108	0,006146	0,006214	2,002303

Entre as redes, a LSTM obteve MSE macro médio 17,2% menor que o Transformer. Com 5 e 5 seeds, porém, a diferença não é estatisticamente significativa (teste de Welch,

Tabela 7.3: MSE macro por regime da razão de ramificação g.

Estimador	g baixo	g intermediário	g quase crítico
LSTM	0,019941	0,015614	0,023297
Transformer	0,022228	0,018964	0,029908
MLE	1,480568	0,016795	0,021214

$p = 0,19$), e os intervalos de confiança se sobrepõem; os dados não permitem ordenar as redes. A comparação deve considerar conjuntamente erro, estabilidade entre seeds e custo de inferência, e não apenas a melhor seed isolada.

No MLE, o parâmetro β respondeu por 98,9% da soma dos erros quadráticos, e o MSE macro no regime de g baixo foi 88,15 vezes o do regime intermediário: com excitação fraca, β é pouco identificado e algumas trajetórias produzem estimativas extremas. Fora desse regime, o MLE é competitivo: no regime intermediário, seu MSE macro foi 0,0168 (LSTM: 0,0156; Transformer: 0,0190) e, no quase crítico, 0,0212 (LSTM: 0,0233; Transformer: 0,0299). O MLE obteve o menor MSE entre os três estimadores em α_{self} e α_{cross}. Portanto, o MSE macro agregado não ordena os estimadores de forma robusta, e convergência numérica não implica boa recuperação paramétrica.

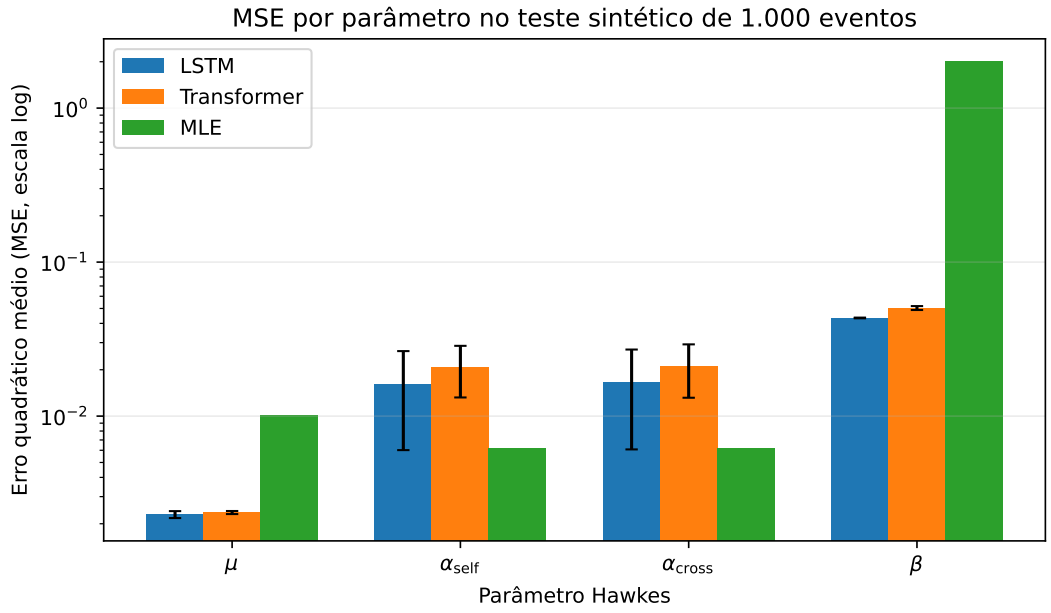


Figura 7.1: MSE de teste por parâmetro no protocolo de 1.000 eventos. As barras de erro das redes representam um desvio-padrão entre seeds.

O MLE convergiu em 100,00% das trajetórias e usou mediana de 14,00 iterações. Todas as comparações usam o mesmo conjunto de teste congelado.

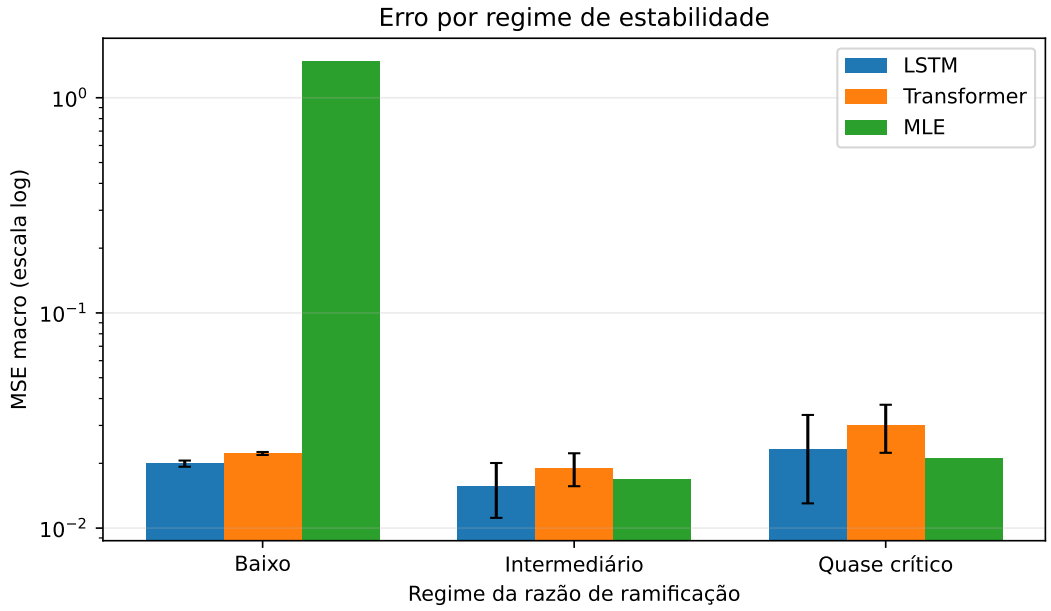


Figura 7.2: MSE macro por regime da razão de ramificação. As barras de erro das redes representam um desvio-padrão entre seeds.

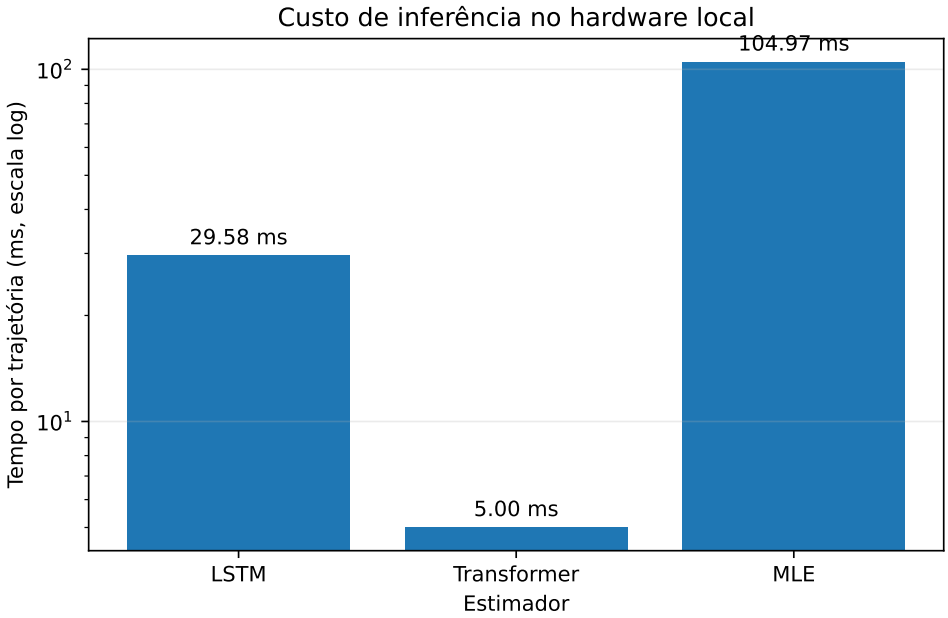


Figura 7.3: Custo por trajetória registrado durante a execução final, em escala logarítmica. Para o MLE, tempo de parede com quatro processos que concorriam com o treino na GPU; para as redes, latência mediana em batch unitário no MPS. Um benchmark controlado posterior mediu cerca de 10 ms por trajetória para o MLE em um único núcleo e deve ser preferido a esta figura.

Capítulo 8

Atualização de 30/10/2026: análise complementar

Este capítulo acrescenta análises feitas depois da execução final, sem retreino e sem abrir o teste empírico: o experimento E2 no ponto fixo de Lee [6], métricas robustas e testes pareados no teste sintético, o diagnóstico do MLE e a calibração em janelas reais. Um benchmark controlado também mostrou que o MLE custa cerca de 10 ms por trajetória em um núcleo, e não 105 ms, valor registrado enquanto o treino ocupava a GPU.

8.1 Ponto fixo do artigo (E2)

Tabela 8.1: Distribuição amostral no ponto fixo de Lee [6] ($\mu = 0{,}3$, $\alpha_{\text{self}} = 0{,}4$, $\alpha_{\text{cross}} = 0{,}7$, $\beta = 1{,}5$): média e desvio-padrão em 2.000 trajetórias de 1.000 eventos. As linhas de Lee usam 100.000 trajetórias de 2.000 passos.

	μ		α_{self}		α_{cross}		β	
Estimador	Média	DP	Média	DP	Média	DP	Média	DP
LSTM (ensemble de 5 seeds)	0,3044	0,0365	0,4950	0,0536	0,6245	0,0608	1,5318	0,1436
Transformer (ensemble de 5 seeds)	0,2957	0,0388	0,5280	0,0561	0,6055	0,0620	1,5308	0,1541
MLE heurístico (5 inícios)	0,3065	0,0370	0,3956	0,0728	0,7075	0,0859	1,5156	0,1642
MLE oráculo (início no verdadeiro)	0,3065	0,0370	0,3956	0,0728	0,7075	0,0859	1,5156	0,1642
Lee (2023) rede	0,3151	0,0358	0,4429	0,0661	0,5733	0,0697	1,5736	0,1364
Lee (2023) MLE	0,3036	0,0314	0,3988	0,0500	0,7024	0,0608	1,5078	0,1145

8.2 Análise complementar dos resultados sintéticos

As previsões por trajetória foram recalculadas a partir dos checkpoints congelados (diferença relativa máxima de 10^{-8} em relação ao MSE reportado), sem retreino e sem alterar o protocolo. Como os parâmetros têm escalas diferentes, cada erro quadrático é dividido pela variância do parâmetro no conjunto de treino; o resultado complementar é o R^2 em relação ao estimador trivial que sempre prevê a média a priori.

Tabela 8.2: R^2 por parâmetro em relação à média a priori, erro absoluto mediano macro e MSE da razão de ramificação no teste sintético.

Estimador	μ	α_{self}	α_{cross}	β	EA mediano	MSE de g
Média a priori	−0,01	0,00	−0,01	0,01	0,1908	0,0670
MLE	0,24	0,90	0,90	−15,64	0,0674	0,0023
LSTM (ensemble)	0,84	0,82	0,81	0,65	0,0680	0,0017
Transformer (ensemble)	0,84	0,74	0,73	0,61	0,0765	0,0019

Tabela 8.3: Comparação pareada por trajetória (erro quadrático padronizado médio nos quatro parâmetros). Colunas: perda mediana de A e de B, fração de trajetórias em que A erra menos e IC 95% *bootstrap* da diferença média A−B (negativo favorece A).

A × B	Regime	Med. A	Med. B	A melhor	IC 95% (A−B)
LSTM × Transformer	todos	0,151	0,187	70,2%	[−0,051; −0,047]
LSTM × Transformer	g baixo	0,112	0,131	61,1%	[−0,021; −0,016]
LSTM × Transformer	g intermediário	0,127	0,164	72,8%	[−0,045; −0,041]
LSTM × Transformer	g quase crítico	0,237	0,304	76,7%	[−0,089; −0,081]
LSTM × MLE	todos	0,151	0,149	48,8%	[−9,394; −0,809]
LSTM × MLE	g baixo	0,112	0,199	63,5%	[−26,977; −2,225]
LSTM × MLE	g intermediário	0,127	0,100	40,1%	[−0,040; −0,009]
LSTM × MLE	g quase crítico	0,237	0,183	42,7%	[−0,467; −0,277]
Transformer × MLE	todos	0,187	0,149	43,5%	[−9,376; −0,782]
Transformer × MLE	g baixo	0,131	0,199	59,4%	[−27,686; −2,207]
Transformer × MLE	g intermediário	0,164	0,100	34,2%	[0,002; 0,035]
Transformer × MLE	g quase crítico	0,304	0,183	36,7%	[−0,374; −0,195]

Três conclusões decorrem dessas tabelas. Primeiro, a vantagem das redes sobre o MLE no MSE agregado vem de poucas trajetórias: 94,4% da soma dos erros quadráticos de β do MLE se concentra em 1% das trajetórias, quase todas no regime de g baixo. Em todas as 300 piores, a log-verossimilhança no estimador supera a do parâmetro verdadeiro (ganho mediano de 2,80), e reajustar 100 delas com 20 inícios praticamente não altera o

resultado. Não é falha numérica: com excitação fraca, β é pouco identificado em 1.000 eventos. Segundo, na trajetória típica o MLE é tão bom quanto as redes ou melhor: a perda mediana é praticamente igual à da LSTM no agregado e menor nos regimes intermediário e quase crítico. Terceiro, na comparação pareada o ensemble LSTM supera o ensemble Transformer em todos os regimes; entre seeds isoladas, contudo, a diferença não é significativa (Welch, $p = 0,19$; Mann–Whitney, $p = 0,056$), porque a LSTM apresentou dois níveis de convergência entre seeds.

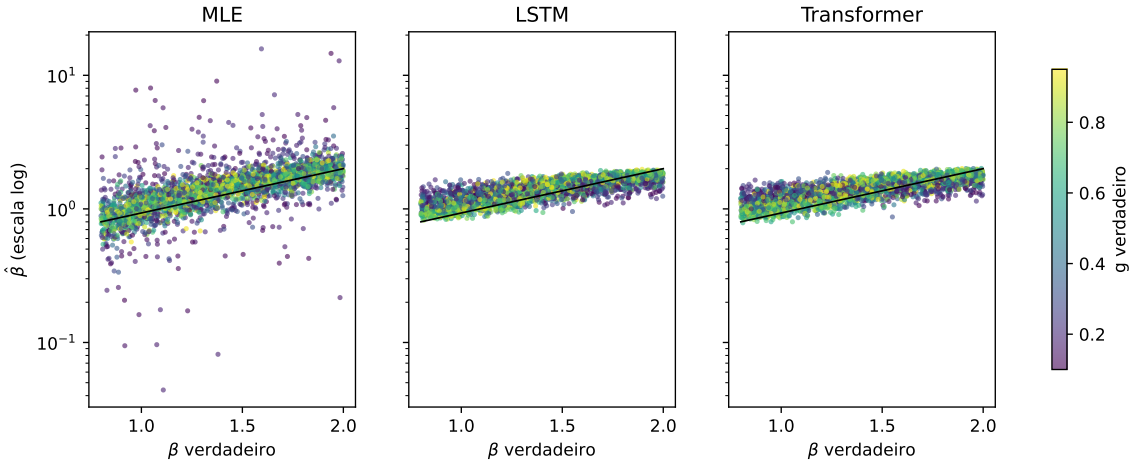


Figura 8.1: β verdadeiro versus estimado (3.000 trajetórias de teste, escala logarítmica). As redes encolhem as estimativas para o centro do prior; o MLE é não viesado na maior parte do domínio, mas produz valores extremos quando g é baixo.

8.3 Calibração empírica e suporte do prior sintético

O MLE foi ajustado nas 1063 janelas de 1.000 eventos do bloco `calibration_train` (15 a 22 de janeiro de 2024), único bloco autorizado para calibração. A mediana de β foi 2,71 (intervalo interquartil 2,21–3,14), acima do limite de 2,0 usado no treino, e α_{cross} ficou abaixo de 10^{-3} em 89,4% das janelas. Apenas 15,4% das janelas têm β dentro do prior, 0,4% têm a fração autoexcitada dentro de [0,2; 0,8] e 0,0% satisfazem todas as faixas ao mesmo tempo. Como um estimador treinado com perda quadrática aproxima a média a posteriori sob o prior de treino, as redes atuais não podem produzir estimativas nessa região; a avaliação empírica exige recalibrar o prior ou treinar com rótulos MLE em janelas reais.

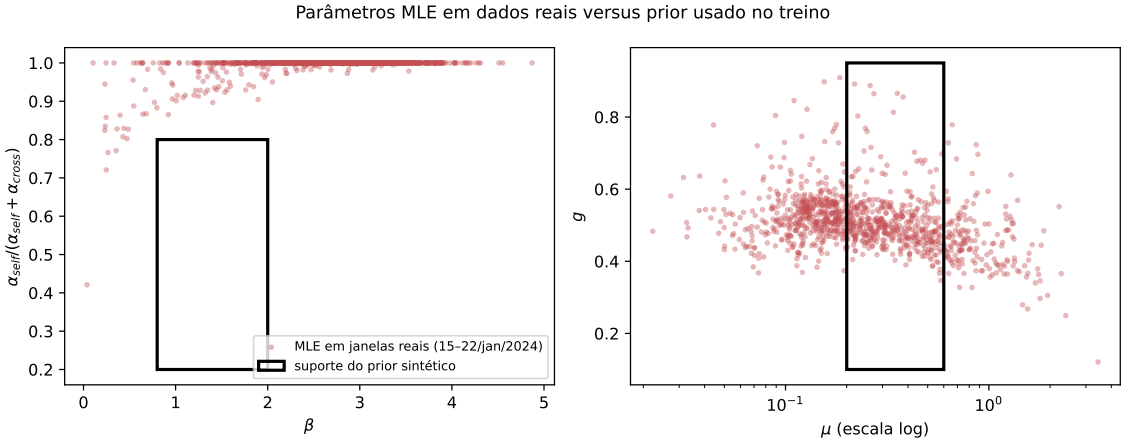


Figura 8.2: Estimativas MLE nas janelas reais de calibração (pontos) e suporte do prior usado para gerar os dados de treino (retângulos).

Capítulo 9

Próximas etapas

1. treinar com rótulos MLE em janelas reais ou recalibrar o prior pelas 1.063 janelas de calibração e retreinar;
2. abrir o teste empírico após congelar a escolha e avaliar outubro sem retreinar;
3. calcular volatilidade Hawkes e realized volatility [1];
4. ampliar a análise de sensibilidade sem ajustar decisões no teste sintético.

Apêndice A

Comandos de reprodução

```
uv sync --python 3.13 --extra dev
uv run python scripts/build_primary_dataset.py --workers 4
uv run python scripts/index_event_windows.py
uv run python scripts/run_empirical_mle.py --max-per-split 1
uv run python scripts/run_model_comparison.py \
  --train-size 1024 --test-size 128 --sequence-length 128 --epochs 3
uv run ruff check .
uv run mypy src/hawkes_crypto
uv run pytest
```

Referências Bibliográficas

[1] Torben G. Andersen, Tim Bollerslev, Francis X. Diebold, and Paul Labys. Modeling and forecasting realized volatility. *Econometrica*, 71(2):579–625, 2003. doi: 10.1111/1468-0262.00418.

[2] Emmanuel Bacry, Sylvain Delattre, Marc Hoffmann, and Jean-François Muzy. Modelling microstructure noise with mutually exciting point processes. *Quantitative Finance*, 13(1):65–77, 2013. doi: 10.1080/14697688.2011.647054.

[3] Binance. Binance Public Data. `https://data.binance.vision` e `https://github.com/binance/binance-public-data`, 2026. Acesso em 31 ago. 2026.

[4] Alan G. Hawkes. Spectra of some self-exciting and mutually exciting point processes. *Biometrika*, 58(1):83–90, 1971. doi: 10.1093/biomet/58.1.83.

[5] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735.

[6] Kyungsub Lee. Recurrent neural network based parameter estimation of Hawkes model on high-frequency financial data. *Finance Research Letters*, 55:103922, 2023. doi: 10.1016/j.frl.2023.103922.

[7] Yosihiko Ogata. On Lewis' simulation method for point processes. *IEEE Transactions on Information Theory*, 27(1):23–31, 1981. doi: 10.1109/TIT.1981.1056305.

[8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran As-

sociates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.